Echo-Search

Un sistema anti–echo–chamber per la ricerca su temi divisivi



Davide Cinelli, Giuseppe Cuiuri

Information Retrieval e NLP · Università della Calabria · Luglio 2026

Il problema e la domanda

Il problema

I motori di ricerca ottimizzano la **pertinenza**, non la **diversità**. Su un tema divisivo la query porta con sé un'inclinazione, e il ranking la amplifica.

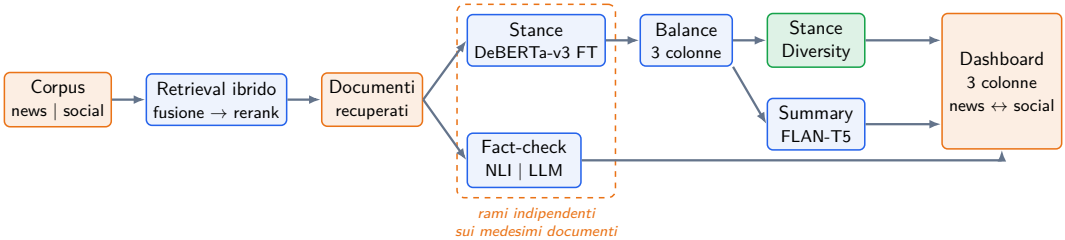
La domanda

Si può **misurare** quanto un ecosistema informativo sia omogeneo nelle opinioni, partendo dai documenti stessi?

- **Intervento**: i risultati non sono una lista, sono tre colonne FAVOR / NEUTRAL / AGAINST affiancate.
- **Misura**: la Stance Diversity — entropia di Shannon normalizzata sulle stance dei risultati.
- **Confronto**: la stessa pipeline su due ecosistemi (news e social), senza differenze di trattamento.

Temi: energia nucleare · cambiamento climatico · vaccini.

Architettura: un DAG, non una catena



Le dipendenze reali dei dati

- Stance e fact-check operano *entrambi* sui documenti recuperati, indipendenti fra loro.
- **Balance** consuma le stance; **summary** consuma le colonne.

Perché la distinzione conta

- il fact-check non è sul cammino critico, ed è il modulo più lento ($\approx$4 s/claim col motore LLM): sovrapponibile.
- la pipeline gira *identica* su ciascun ecosistema.

Corpus a due ecosistemi — e le sue fonti

Media / news

CC-News (`vblagoje/cc_news`).
708 241 articoli scansionati; filtri per densità di parole chiave e tetto del 15% per dominio.

403 nucleare · **800** clima · **714** vaccini

Social (tweet etichettati)

Clima — `edwardcqian/climate_change_sentiment` (GitHub): campo `message`, label `sentiment` $\in \{1, -1, 0\}$; la classe "News" è scartata. **999** tweet.

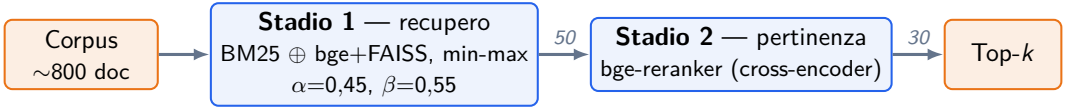
Vaccini — `sohampoddar26/covid-vax-stance` (GitHub): campo `tweet`, label `majority_label` $\in$ {ProVax, AntiVax, Neutral}. **870** tweet.

Scaricati da *raw* GitHub: nessuna API Twitter, quindi riproducibili. Dedup per testo normalizzato.

Avvertenza metodologica, dichiarata

Il corpus social è campionato in modo **stratificato** sulle tre stance (333/333/333 clima, 290/290/290 vaccini): la sua entropia a priori vale **1,000 per costruzione**. Serviva per valutare lo stance detector sulla classe AGAINST, quasi assente nella cronaca ($\approx$3%). Ma rende il *confronto* di diversity con le news confondato: si veda la slide dedicata.

Motore di ricerca: due stadi



- **Complementari, non alternativi**: la fusione *recupera*, il reranker *riordina*. Il tetto del reranker è il recall dello stadio 1.
- **BM25 con** $b = 0{,}60$ (non 0,75): su articoli tutti lunghi, penalizzare la lunghezza scarta proprio i pezzi ricchi di evidenze.
- **bge è asimmetrico**: prefisso-istruzione solo sulle query, mai sui passaggi.
- Aggregazione **max-pooling** sui chunk: un documento è rilevante se *almeno un* suo chunk lo è.

Retrieval — ablazione su qrels annotati

#	Sistema	NDCG@10	MAP@20	Recall@20
1	BM25 puro	0,616	0,488	0,583
2	Denso puro (bge)	0,656	0,538	0,701
3	Fusione RRF	0,653	0,535	0,671
4	Fusione, α=0,45	0,674	0,556	**0,702**
5	Fusione, α tarato (LOTO)	0,644	0,538	0,685
6	**Fusione + reranking**	**0,715**	**0,577**	**0,702**

- Il **reranking** è il contributo più grande: +6,1% relativo, a Recall invariato — riordina, non recupera. Il guadagno viene quasi tutto dai vaccini (0,599 → 0,722): serve dove il primo stadio lascia margine.
- La fusione batte entrambi i rami singoli *e* la baseline RRF.

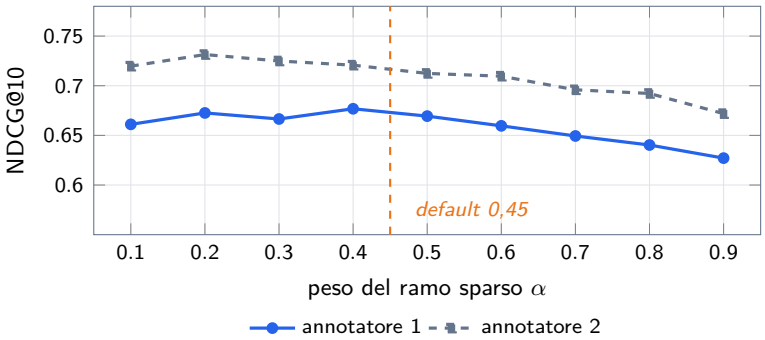
Il divario fra rami si ribalta:

NDCG@10	nucleare	clima
BM25 puro	**0,800**	0,405
Denso puro	0,737	**0,576**

termini tecnici *vs* parafrasi: è la complementarità che motiva la fusione.

Metriche sui qrels del primo annotatore; il secondo li replica (v. slide successive).

Retrieval — tarare α non serve



- Fra 0,1 e 0,5 la metrica è **piatta**: escursione di 1,6 punti. L'ottimo oracolo (α=0,4) vale +0,4% sul default.
- I due annotatori collocano l'ottimo in punti diversi (0,4 *vs* 0,2): è rumore.
- Tarare in leave-one-topic-out **peggiora** (0,644 *vs* 0,674): con due temi di training si seleziona quel rumore.

Qrels: protocollo e accordo fra annotatori

Pool alla Cranfield, unione di 5 run: BM25, denso, RRF, fusione, pool del reranker. Profondità 20 ⇒ **380** coppie (query, doc).

143 su 380 — il 38% — vengono da un solo run: pescare dalla sola fusione le avrebbe rese non giudicate, cioè non rilevanti, falsando l'ablazione a sfavore delle baseline.

Ordine randomizzato, rango e punteggio nascosti all'annotatore (*position bias*).

Doppia annotazione umana in cieco: fogli separati, nessuna consultazione durante il lavoro — l'accordo su annotazioni allineate strada facendo non significherebbe nulla.

Tema	n	Accordo	κ **quad.**
Nucleare	137	0,839	**0,904**
Clima	109	0,761	**0,814**
Vaccini	134	0,784	**0,856**
Totale	**380**	0,797	**0,867**

Almost perfect su tutti i temi (non pesato: 0,675). Scala ordinale ⇒ κ a **pesi quadratici**: quello non pesato tratterebbe "0 vs 1" e "0 vs 2" come lo stesso errore.

77 divergenze su 380, di cui 2 a due gradini: si discute *quanto* un documento serva, non *se* risponda.

Controllo di robustezza: le due serie ordinano allo stesso modo **5 sistemi su 6** (τ_b di Kendall = 1,0); sui 6 scende a 0,733 e l'unico a spostarsi è la *fusione tarata* — per 0,0006 di NDCG, cioè proprio il sistema che concludiamo non servire.

Stance detection

DeBERTa-v3-base, full fine-tuning su **VAST** ∪ **SemEval-2016 T6** (16 097 esempi, 4 644 target distinti). Input a coppia nativo `[CLS] target [SEP] doc [SEP]`.

Selezione del checkpoint su **Macro-F1** di validazione, non sulla loss: con classi sbilanciate la loss sacrifica NEUTRAL.

No MoE, no DANN: il routing non deterministico renderebbe la Macro-F1 non riproducibile. La generalizzazione viene da VAST, a monte.

Test held-out	**Macro-F1**	NEUTRAL
Fine-tuned	**0,771**	**0,858**
Zero-shot NLI	0,390	0,125

Generalizzazione	Macro-F1
VAST (763 target nel test)	0,768
SemEval	0,741
Gold social (tweet)	∼0,48

Il calo sui social è tutto su una classe

NEUTRAL scende a F1 0,07–0,23, mentre FAVOR e AGAINST restano a 0,6–0,7. Non è un degrado generico: il "neutro" sui social è un **costrutto diverso** (ironia, allusione, contesto conversazionale assente). Servirebbe una ri-annotazione dedicata, non più dati.

Stance Diversity — la metrica firma

$$\mathrm{Div}(p) = -\frac{1}{\log 3} \sum_{c \in \{\mathrm{F,N,A}\}} p_c \log p_c \ \in \ [0, 1]$$

- Calcolata sull'intero pool riordinato, **non** sulle colonne mostrate: le colonne sono bilanciate per costruzione, misurarle darebbe una costante travestita da misura.
- Due numeri affiancati nella GUI: la barra = *ciò che il corpus offre*, le colonne = *ciò che il sistema mostra*.

(F, N, A)	Div	lettura
(30, 0, 0)	0,00	echo chamber perfetta
(28, 1, 1)	0,27	quasi unanime
(20, 8, 2)	0,73	minoranza presente
(15, 10, 5)	0,92	sbilanciato ma reale
(10, 10, 10)	1,00	bilanciamento perfetto

Invariante per permutazione delle classi e insensibile alla dimensione del campione: per questo l'interfaccia mostra *sempre* anche la distribuzione.

Stance Diversity — il risultato, e cosa dimostra

Stance Diversity	**News**	**Social**	H a priori del corpus social
Energia nucleare	0,545	—	—
Cambiamento climatico	0,322	**0,621**	1,000
Vaccini	0,229	**0,600**	1,000

Il risultato solido

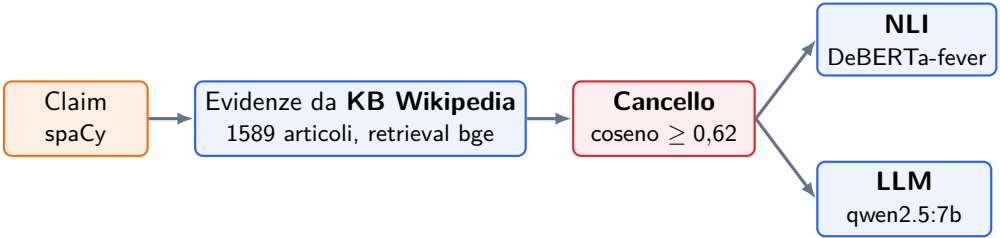
L'ecosistema **news** è marcatamente omogeneo *in senso assoluto*, e due misure indipendenti concordano: diversity 0,23–0,55 sul pool, e ≈**3%** di documenti AGAINST sull'intero corpus.

Il confronto, invece, è confondato

Il social ha entropia a priori 1,000 *per costruzione*, le news quella naturale. La differenza somma un effetto reale ignoto e un artefatto di campionamento di segno noto (positivo): **sovrastima** la conclusione.

Contromisura proposta: *diversity lift* $= H(p_{\text{pool}})/H(p_{\text{corpus}})$, invariante rispetto alla distribuzione a priori. Definita, non ancora calcolata.

Fact-checking: due motori, uno stack



- **Prime due fasi condivise, terza intercambiabile**: cambia *solo* il motore di verdetto $\Rightarrow$ la differenza misurata è attribuibile ad esso.
- **Il cancello di pertinenza** evita i falsi REFUTED: su una KB tematica il retrieval restituisce *sempre* qualcosa, e l'NLI legge "diverso" come "contraddittorio".
- **Grounding puro** per l'LLM: giudica solo sulle evidenze, mai sulla conoscenza parametrica. Tutto locale, nessuna API.

Fact-checking — NLI *vs* LLM a parità di evidenze

ClimateFEVER, claim-level (n=1381)	Acc	**Macro-F1**	SUP	REF	NEI
NLI (DeBERTa-v3-base-mnli-fever-anli)	0,393	0,350	0,065	0,479	0,507
LLM (qwen2.5:7b, grounding puro)	**0,667**	**0,640**	**0,753**	**0,565**	**0,601**
Δ relativo	+70%	**+83%**	**+1058%**	+18%	+19%

Il profilo si ribalta. L'NLI era pessimo nel *confermare* (SUP 0,065) e discreto nel confutare; l'LLM diventa il più forte proprio lì e trova il suo punto debole in REFUTED.

Errori complementari, non uniformemente migliori. Riconoscere una conferma richiede inferenza a più passi; una contraddizione è spesso incompatibilità locale.

Costo: $\approx$4 s/claim contro decine di ms.

Ablazione: la variante *large* dell'NLI dà +1,4 punti di accuracy a costo triplo $\Rightarrow$ si adotta la *base*.

Sintesi e interfaccia

Summarization — FLAN-T5-base, strategia *extract-then-abstract*: BM25 a livello di frase riduce l'input sotto la finestra di contesto, il modello riscrive.

Beam search puro, `do_sample=False`: lo stesso cluster deve produrre sempre lo stesso riassunto.

Non valutata: mancano riassunti di riferimento. È una baseline ragionevole, non un componente validato.

Dashboard (Streamlit)

- Tre colonne affiancate, palette divergente.
- Barra di diversity segmentata: punteggio *e* proporzioni del pool.
- Schede per ecosistema: il confronto news↔social è un clic.
- **Soft-filter**: selezionando una posizione la colonna si allarga, le altre non scompaiono — un filtro rigido ricostruirebbe l'echo chamber.
- Card espandibili con claim, verdetto e link alle fonti.

Query canoniche **precalcolate**: la demo è istantanea e non richiede GPU a runtime (il motore LLM costa minuti per ecosistema).

Quadro d'insieme

Componente	Benchmark	Risultato	Stato
Retrieval, ablazione 6 sistemi	qrels propri (380)	NDCG@10 **0,715**	valutato
Accordo annotatori	2 umani, 380 coppie	κ quad. **0,867**	*almost perfect*
Stance detection	VAST $\cup$ SemEval	Macro-F1 **0,771**	valutato
Stance, cross-dataset	VAST / SemEval	0,768 / 0,741	generalizza
Stance, dominio social	gold social	$\sim$0,48	calo analizzato
Fact-check NLI	ClimateFEVER	Macro-F1 0,350	valutato
Fact-check LLM	ClimateFEVER	Macro-F1 **0,640**	controllato
Stance Diversity	query canoniche	0,229–0,621	confondato
Summarization	—	—	non valutabile

Tutto entro **6 GB** di VRAM, **offline**, con 174 test automatici e manifest con hash SHA-256.

Limiti dichiarati e prossimi passi

Limiti

- **Confronto news/social confondato** dal campionamento stratificato.
- **11 query**: bastano a ordinare i sistemi, non a tarare α né a dare intervalli di confidenza.
- **Qrels non riconciliati**: le 77 divergenze fra i due annotatori non sono state adjudicate in un'unica serie.
- NEUTRAL è un costrutto instabile fuori dai benchmark.
- KB statica: claim recenti $\rightarrow$ evidenza insufficiente.
- Summarization non valutata.

Prossimi passi

- **Diversity lift**: chiude il confondimento principale, costa una passata offline dello stance detector.
- **Più query** (40–50) per intervalli di confidenza e test di significatività.
- **Adjudicare le divergenze** fra i due annotatori in una serie consolidata.
- **Combinare i due motori** di fact-check: i profili di errore sono complementari.
- Persistenza dell'indice KB; parallelizzazione del ramo fact-check.

Echo-Search

Tre cose che il progetto lascia:

- l'echo chamber diventa una **grandezza misurabile** sui contenuti, non sulle relazioni — con le condizioni sotto cui il confronto è lecito rese esplicite;
- a parità di evidenze, un LLM locale che **ragiona** supera un NLI specializzato proprio dove questo falliva, con errori *complementari*;
- sul retrieval, il **secondo stadio** vale dieci volte qualunque taratura di iperparametri — e i default motivati dal dominio erano già ottimi.

Davide Cinelli | Giuseppe Cuiuri