Echo-Search

Un sistema anti–echo–chamber per la ricerca
su temi divisivi

Relazione di progetto

Information Retrieval e Natural Language Processing



Davide Cinelli | Giuseppe Cuiuri

Università della Calabria — A.A. 2025/2026

Luglio 2026

Indice

1 Introduzione **3**

1.1 Contesto e problema . . . 3
1.2 Domande di ricerca . . . 3
1.3 Contributi . . . 4
1.4 Che cosa questo lavoro non è . . . 4
1.5 Struttura . . . 4

2 Background **5**

2.1 Echo chamber e diversità dei risultati . . . 5
2.2 Information Retrieval . . . 5
2.2.1 Retrieval sparso . . . 5
2.2.2 Retrieval denso e indici vettoriali . . . 5
2.2.3 Retrieval ibrido e reranking . . . 6
2.2.4 Valutazione . . . 6
2.3 Stance detection . . . 7
2.4 Fact-checking e Natural Language Inference . . . 7
2.5 Misure di diversità . . . 8
2.6 Posizionamento . . . 8

3 Il sistema **9**

3.1 Visione d'insieme . . . 9
3.2 I moduli NLP sono un DAG, non una catena . . . 9
3.3 Corpus a due ecosistemi . . . 9
3.4 Scelte di progettazione e alternative scartate . . . 9
3.5 Il vincolo hardware come vincolo di progetto . . . 11
3.6 Organizzazione del codice . . . 11
3.7 Interfaccia . . . 12

4 Dati **13**

4.1 Temi e target . . . 13
4.2 Corpus news: CC-News . . . 13
4.3 Corpus social . . . 14
4.4 Knowledge base, dataset di stance e benchmark . . . 15
4.5 Riproducibilità dei dati . . . 16

5 Metodologia **17**

5.1 Preprocessing . . . 17
5.2 Retrieval, stadio 1: fusione . . . 17
5.3 Retrieval, stadio 2: reranking . . . 18
5.4 Stance detection . . . 18
5.5 Bilanciamento e Stance Diversity . . . 19

5.6 Fact-checking . . . 20
5.7 Summarization . . . 21

6 Protocollo sperimentale **23**
6.1 Principi e ambiente . . . 23
6.2 Metriche . . . 23
6.3 Protocollo: stance detection . . . 23
6.4 Protocollo: fact-checking . . . 24
6.5 Protocollo: Stance Diversity . . . 24
6.6 Protocollo: retrieval . . . 24
6.7 Ciò che non viene valutato . . . 25

7 Risultati **26**
7.1 Stance detection . . . 26
7.2 Fact-checking su ClimateFEVER . . . 26
7.3 Stance Diversity: media contro social . . . 28
7.4 Retrieval . . . 29
7.4.1 Accordo fra annotatori . . . 29
7.4.2 Ablazione dei sistemi . . . 29
7.5 Quadro d'insieme . . . 31

8 Discussione e limiti **33**
8.1 Findings trasversali . . . 33
8.2 Analisi degli errori . . . 33
8.3 Minacce alla validità . . . 34
8.3.1 Validità interna . . . 34
8.3.2 Validità esterna . . . 35
8.3.3 Validità di costrutto . . . 35
8.3.4 Validità delle conclusioni statistiche . . . 35
8.4 Limiti . . . 36
8.5 Considerazioni etiche . . . 36

9 Conclusioni **38**
9.1 Che cosa è stato ottenuto . . . 38
9.2 Due lezioni trasversali . . . 38
9.3 Sviluppi futuri . . . 39

A Iperparametri **40**

B Prompt del motore LLM **41**

C Linee guida di annotazione dei qrels **42**

D Riproducibilità **43**

1. Introduzione

1.1 Contesto e problema

Il dibattito pubblico sui temi controversi si svolge sempre più in ambienti informativi che, per effetto combinato della personalizzazione algoritmica e dell'omofilia sociale, espongono l'utente prevalentemente a contenuti concordi con le sue opinioni pregresse — il fenomeno noto come *echo chamber*, o *filter bubble* nella sua variante algoritmica [12, 4]. Su temi ad alto contenuto tecnico e forte carica valoriale come l'energia nucleare, il cambiamento climatico e la vaccinazione, la formazione di un'opinione informata richiederebbe accesso bilanciato alle argomentazioni di entrambe le parti, corredate da evidenze verificabili.

Gli strumenti di ricerca, però, sono ottimizzati per la *pertinenza* e non per la *diversità*. Dato un corpus $\mathcal{D}$, una query q e un *target* di dibattito t, un motore classico restituisce

$$R_k(q) = \arg\text{top-}k_{d\in\mathcal{D}}\ \mathrm{rel}(q, d), \tag{1.1}$$

e nulla in questa formulazione vincola la distribuzione delle posizioni $s(d, t)$ all'interno di $R_k(q)$, dove $s(d, t) \in \{\textsc{favor}, \textsc{neutral}, \textsc{against}\}$: se fra i documenti più pertinenti ce ne sono 18 favorevoli e 2 contrari, il sistema ne mostra 18 e 2. Poiché la query stessa porta con sé un'inclinazione implicita ("*risks* of nuclear energy" e "*benefits* of nuclear energy" pescano da regioni diverse del corpus), il ranking per pertinenza è un amplificatore involontario dell'echo chamber.

Il problema ha due livelli, che questo lavoro tiene distinti. Al livello dell'**esposizione** — quali documenti vengono mostrati — è possibile intervenire, diversificando il result set. Al livello dell'**ambiente** — quali documenti esistono nel corpus, e con quale distribuzione di posizioni — non c'è intervento possibile: c'è una proprietà da misurare. **Echo-Search** si colloca all'intersezione: sostituisce l'output piatto con tre colonne di prospettiva contrapposta, e misura contestualmente quanto plurale sia il materiale che il corpus rende disponibile per quella query.

1.2 Domande di ricerca

RQ1 — Misurabilità
È possibile operazionalizzare l'omogeneità di opinione di un insieme di risultati in una metrica scalare, interpretabile e confrontabile fra corpora?

RQ2 — Confronto fra ecosistemi
L'ecosistema social e quello dei media differiscono, sugli stessi temi, per diversità di stance del materiale che rendono recuperabile? In quale direzione?

RQ3 — Motore di verdetto
Nel fact-checking *a parità di evidenze*, un LLM generalista di taglia contenuta ($\leq$10B) che *ragiona* è competitivo con un classificatore NLI specializzato e FEVER-tuned?

RQ4 — Fattibilità
È possibile realizzare l'intera pipeline in modo locale, offline e riproducibile entro 6 GB di memoria video?

Anticipiamo il grado di risposta raggiunto: RQ1, RQ3 e RQ4 ricevono risposta affermativa e documentata; RQ2 riceve una risposta *condizionata*, la cui validità interna è limitata dal modo in cui i due corpora sono stati costruiti — limite analizzato nella Sezione 8.3.1 e non nascosto.

1.3 Contributi

1. **Una pipeline simmetrica a due ecosistemi**: la medesima catena, con gli stessi modelli e parametri, su due corpora indicizzati separatamente. È la simmetria a rendere confrontabili i risultati.
2. **Una metrica di echo chamber**, la *Stance Diversity*, con l'analisi delle sue proprietà e delle condizioni sotto cui il confronto fra due valori è lecito.
3. **Un fact-checker locale a due motori intercambiabili**: stessa knowledge base, stesso recupero, stesso cancello di pertinenza; cambia solo il modulo che emette il verdetto. È questo isolamento a rendere il confronto un esperimento controllato.
4. **Uno stance detector fine-tunato**, valutato su benchmark citabili, in *cross-dataset* e su un gold set nel dominio applicativo.
5. **Una valutazione del retrieval su qrels propri**, doppiamente annotati da due persone in cieco, con ablazione a sei sistemi e misura di quanto l'ordinamento dipenda da chi ha giudicato.

1.4 Che cosa questo lavoro non è

Non è un contributo modellistico: nessuna architettura nuova, nessuna funzione di perdita nuova; l'unico addestramento è un fine-tuning supervisionato standard. Non è uno studio sociologico sulla polarizzazione: i corpora sono campioni di dimensione limitata, scelti per rendere il sistema eseguibile e riproducibile, non per essere rappresentativi dell'ecosistema mediatico. Le conclusioni sulla differenza fra media e social vanno lette come proprietà *dei corpora costruiti*. Non è infine un sistema di moderazione: il registro di credibilità delle fonti è usato per descrivere i dati, mai come filtro automatico sui risultati mostrati.

1.5 Struttura

Il Capitolo 2 richiama il background necessario a giustificare le scelte. Il Capitolo 3 descrive architettura e implementazione. Il Capitolo 4 documenta i dati — capitolo cruciale, perché è lì che nascono sia i risultati sia i loro limiti. Il Capitolo 5 formalizza la metodologia; il Capitolo 6 definisce il protocollo sperimentale *prima* di vederne i risultati, che sono nel Capitolo 7. Il Capitolo 8 discute findings, errori e minacce alla validità; il Capitolo 9 conclude.

2. Background

2.1 Echo chamber e diversità dei risultati

Il termine *echo chamber* descrive un ambiente in cui le convinzioni sono amplificate per ripetizione, con esposizione limitata a punti di vista alternativi; la variante *filter bubble* [12] enfatizza la componente algoritmica. Sul piano empirico l'ambito computazionale ha proceduto su due direttrici quasi sempre separate: la *misura* della polarizzazione — tipicamente su grafi di interazione sociale, come in Cinelli et al. [4] — e l'*intervento*, cioè l'esposizione deliberata a contenuti discordanti. Misurare la polarizzazione direttamente sui *contenuti testuali*, tramite stance detection, è una strada meno battuta e più direttamente collegabile a un motore di ricerca.

La diversificazione dei risultati ha una tradizione consolidata nell'IR, nata però per un problema diverso: l'ambiguità della query. In *Maximal Marginal Relevance* [3] si premia la rilevanza e si penalizza la ridondanza *testuale*; approcci successivi esplicitano i sotto-argomenti da coprire. La differenza rispetto a **Echo-Search** è sostanziale: là la diversità è dissimilarità nello spazio delle rappresentazioni, qui è definita *a priori* e semanticamente — le tre stance. Ne consegue che la misura è direttamente interpretabile e confrontabile fra corpora, ma anche che la sua qualità dipende da quella del classificatore di stance, con un errore di misura di cui va reso conto.

2.2 Information Retrieval

2.2.1 Retrieval sparso

La famiglia *Best Matching* culmina in BM25 [2], tuttora una baseline difficile da battere:

$$\mathrm{BM25}(D,Q) = \sum_{t \in Q} \mathrm{IDF}(t) \cdot \frac{f(t,D)\,(k_1+1)}{f(t,D) + k_1 \left(1 - b + b\,\dfrac{|D|}{\mathrm{avgdl}}\right)}. \tag{2.1}$$

I due iperparametri hanno interpretazioni distinte e non intercambiabili. Il parametro k_1 governa la *saturazione* della term-frequency: per $k_1 \to 0$ il contributo di un termine diventa binario, per k_1 grande cresce quasi linearmente. Il parametro $b \in [0,1]$ governa la *normalizzazione per lunghezza*: con $b = 0$ la lunghezza è ignorata, con $b = 1$ la normalizzazione è piena. Il default $b = 0{,}75$ è tarato su collezioni web eterogenee; questa osservazione motiva la scelta adottata nella Sezione 5.2. Il limite strutturale di BM25 è il *vocabulary mismatch*: essendo lessicale, non riconosce che "meltdown" e "nuclear accident" denotano lo stesso evento — limite tanto più rilevante su un dominio argomentativo, dove la stessa posizione si esprime con lessici molto diversi a seconda dell'orientamento della fonte.

2.2.2 Retrieval denso e indici vettoriali

I metodi *dense* proiettano i testi in uno spazio semantico tramite *bi-encoder*: query e documento sono codificati *separatamente* e la rilevanza è approssimata dalla similarità coseno, con

addestramento per *contrastive learning* su grandi collezioni di coppie [9]. Il vantaggio è decisivo: i documenti si codificano offline una volta sola. Il modello adottato, *bge-base-en-v1.5* [1], è *asimmetrico*: prevede un prefisso-istruzione sulla query e nessun prefisso sui passaggi. Ignorare l'asimmetria degrada silenziosamente il recupero senza generare alcun errore — difetto insidioso e frequente.

Su vettori L2-normalizzati il prodotto interno coincide con la similarità coseno, e librerie come FAISS [10] offrono indici *esatti* o *approssimati*. Per collezioni dell'ordine di 10^3–10^4 vettori l'indice esatto è preferibile: il costo è trascurabile e si ottiene in cambio la riproducibilità perfetta dei risultati, requisito non negoziabile in un contesto di valutazione.

Il limite dei bi-encoder è l'assenza di interazione fra query e documento, che il secondo stadio è chiamato a recuperare.

2.2.3 Retrieval ibrido e reranking

Poiché segnale lessicale e semantico sono complementari, lo stato dell'arte li combina, con due strategie dalle proprietà diverse. La *fusione di punteggi* normalizza e combina linearmente,

$$\mathrm{score}(d) = \alpha\, \widetilde{s}_{\mathrm{sparse}}(d) + \beta\, \widetilde{s}_{\mathrm{dense}}(d), \qquad \alpha + \beta = 1, \tag{2.2}$$

conservando l'informazione sulla *magnitudo* delle differenze, al prezzo di dipendere dalla normalizzazione e di richiedere la taratura di α. La *fusione di ranghi*, di cui *Reciprocal Rank Fusion* [14] è il rappresentante più usato,

$$\mathrm{RRF}(d) = \sum_{r \in \mathcal{R}} \frac{1}{k_{\mathrm{rrf}} + \mathrm{rank}_r(d)}, \tag{2.3}$$

è robusta e priva di parametri, ma perde quell'informazione: due documenti in posizione 1 e 2 contribuiscono quasi allo stesso modo, che siano separati da un abisso o da un niente.

Un secondo stadio di *reranking* affina l'ordinamento con un *cross-encoder*, che riceve query e documento *insieme* e ne modella l'interazione con attenzione completa [15]: sistematicamente più preciso del bi-encoder, ma con costo $O(N)$ per query e non precomputabile. Ne discende lo schema *retrieve-then-rerank*: uno stadio economico e ad alto recall su tutto il corpus, seguito da uno costoso e preciso su poche decine di candidati. I due stadi non sono alternativi: la fusione *recupera*, il reranker *riordina*, e il tetto di prestazione del secondo è fissato dal recall del primo.

2.2.4 Valutazione

Il paradigma dominante resta quello di Cranfield: una collezione, un insieme di query e un insieme di *giudizi di rilevanza* (*qrels*). Poiché giudicare l'intero corpus è impraticabile, si ricorre al *pooling*: si uniscono i primi k risultati di tutti i sistemi in esame e si giudica solo l'unione, assumendo non rilevanti i documenti mai entrati nel pool. Le metriche standard sono il *Normalized Discounted Cumulative Gain*

$$\mathrm{DCG@}k = \sum_{i=1}^{k} \frac{\mathrm{rel}_i}{\log_2(i+1)}, \qquad \mathrm{NDCG@}k = \frac{\mathrm{DCG@}k}{\mathrm{IDCG@}k}, \tag{2.4}$$

che premia i rilevanti nelle prime posizioni ed è definito per giudizi graduati; la *Mean Average Precision*; e il *Recall@k*, che è la metrica corretta per valutare uno stadio di generazione dei candidati. L'accordo fra annotatori si riporta convenzionalmente con il κ di Cohen [7].

2.3 Stance detection

La stance detection classifica la posizione di un testo verso un *target* in FAVOR, AGAINST, NEUTRAL. Va distinta dalla *sentiment analysis*: un testo può esprimere sentimento negativo ed essere a favore del target ("è *tragico* che la disinformazione stia rallentando le vaccinazioni"). I benchmark di riferimento sono **SemEval-2016 Task 6** [16], su tweet e cinque target predefiniti, e **VAST** [18], con migliaia di target diversi e quindi riferimento per la generalizzazione *cross-target*. L'approccio dominante fine-tuna transformer pre-addestrati su input a coppia `[CLS] target [SEP] testo [SEP]`: la codifica a coppia è preferibile alla concatenazione manuale perché sfrutta i *token type embeddings* nativi.

Tre difficoltà sono documentate in letteratura e si ripresentano puntualmente in questo lavoro: la **dipendenza dal target** (la stringa scelta per rappresentarlo influenza sensibilmente le prestazioni); la classe **NEUTRAL**, notoriamente la peggio classificata perché raccoglie fenomeni eterogenei — testi informativi, ambigui, ironici, che riportano posizioni altrui; e la **sensibilità al dominio**. Un'alternativa senza addestramento è l'uso di modelli NLI in *zero-shot* [19], adottata qui come baseline.

2.4 Fact-checking e Natural Language Inference

La verifica automatica di affermazioni è convenzionalmente scomposta in tre fasi, secondo l'architettura di FEVER [11]: estrazione della *claim*, recupero delle *evidenze*, formulazione del *verdetto*. La scomposizione ha un pregio metodologico: rende ogni fase valutabile in isolamento, evitando che un errore di recupero venga attribuito al motore di verdetto.

La terza fase è tipicamente modellata come *Natural Language Inference*: data una coppia (premessa, ipotesi) si predice se la prima *implica*, *contraddice* o è *neutrale* rispetto alla seconda, con corrispondenza diretta ai verdetti SUPPORTED / REFUTED / NOT_ENOUGH_INFO. **ClimateFEVER** [6] adatta il paradigma a claim climatiche reali: benchmark sensibilmente più difficile di FEVER, perché le claim sono formulate in linguaggio non controllato, spesso vaghe o parzialmente vere.

Più recentemente i *Large Language Model* vengono impiegati come motore di verdetto, sfruttandone la capacità inferenziale generale al posto della specializzazione. Il rischio noto è che il modello risponda sulla base della conoscenza parametrica anziché delle evidenze fornite, il che invaliderebbe il confronto con l'NLI e aprirebbe la porta alle allucinazioni; la contromisura standard è il *grounding* esplicito nel prompt. Il paradigma generale del recupero di evidenze a supporto della generazione è quello della *Retrieval-Augmented Generation* [13].

2.5 Misure di diversità

Per quantificare l'eterogeneità di una distribuzione categoriale lo strumento canonico è l'**entropia di Shannon** [17], $H(p) = -\sum_c p_c \log p_c$, massima e pari a $\log K$ per la distribuzione uniforme e nulla per una distribuzione degenere. La normalizzazione $H(p)/\log K$ produce un valore in $[0, 1]$ interpretabile e confrontabile. Alternative possibili sono l'indice di Gini-Simpson, che pesa meno le categorie rare, e i numeri di Hill. L'entropia normalizzata è preferibile qui perché è la scelta più diffusa e quindi confrontabile con la letteratura, ha un'interpretazione informazionale precisa, e penalizza fortemente le distribuzioni degeneri — che è esattamente il comportamento desiderato quando l'obiettivo è segnalare un'echo chamber.

Va però sottolineato un punto che il Capitolo 8 riprende: l'entropia è funzione della sola distribuzione e non sa nulla di *come* quella distribuzione sia stata generata. Confrontare $H(p_1)$ e $H(p_2)$ è informativo solo se i due campioni provengono da procedure comparabili. Questa condizione, apparentemente ovvia, è il punto delicato dell'intero lavoro.

2.6 Posizionamento

Echo-Search non propone nuovi modelli: il suo contributo è di *sistema* e di *metodo di misura*. I due elementi di originalità sono l'operazionalizzazione dell'echo chamber come metrica scalare comparabile fra ecosistemi, calcolata sui contenuti e non sulle relazioni sociali; e un banco di prova per il fact-checking in cui il motore di verdetto è l'*unica* variabile che cambia, il che consente di attribuire la differenza di prestazione al motore e non alla catena di recupero.

3. Il sistema

3.1 Visione d'insieme

Il sistema è un motore di retrieval a due stadi seguito da moduli NLP che arricchiscono i documenti recuperati (Figura 3.1). Il principio guida è la **simmetria fra ecosistemi**: la medesima pipeline, con gli stessi modelli e iperparametri, viene eseguita su ciascuno dei due ecosistemi (media/news e social); è il *confronto* fra i due blocchi a costituire l'output di ricerca.

La simmetria non è un dettaglio estetico ma un requisito sperimentale: se i due ecosistemi fossero trattati diversamente, ogni differenza osservata sarebbe attribuibile tanto all'ecosistema quanto al trattamento. Vincolare la pipeline a essere identica elimina per costruzione un'intera classe di confondimenti — ne resta un'altra, di natura diversa, discussa nella Sezione 8.3.1.

3.2 I moduli NLP sono un DAG, non una catena

Una precisazione architetturale importante: i quattro moduli NLP *non* formano una catena in cui l'output di ciascuno è l'input del successivo. Analizzando le dipendenze dei dati, **stance** e **fact-check** operano entrambi direttamente sui documenti recuperati e in modo reciprocamente indipendente — il verdetto di fact-checking non richiede la stance, né viceversa — e sono quindi concettualmente parallelizzabili; **balance** dipende dalle stance, che usa per comporre le colonne e calcolare la diversità; **summary** dipende dalle colonne bilanciate.

La distinzione ha una conseguenza pratica: il cammino critico è retrieval $\rightarrow$ stance $\rightarrow$ balance $\rightarrow$ summary, mentre il fact-checking — di gran lunga il modulo più lento con il motore LLM — non vi appartiene e potrebbe essere sovrapposto. Nell'implementazione attuale i due rami sono eseguiti in sequenza. Si osservi inoltre che il fact-check è applicato *dopo* il bilanciamento e non a tutti i documenti recuperati: non è una dipendenza logica ma un'ottimizzazione, poiché verificare documenti che verranno scartati costerebbe il doppio senza beneficio per l'utente.

3.3 Corpus a due ecosistemi

Per ciascun tema si mantengono due corpora fisicamente separati e indicizzati in modo indipendente. La separazione è essenziale: con un indice unico il retrieval sceglierebbe fra le due popolazioni in base alla sola pertinenza, e un tweet di venti parole competerebbe con un articolo di duemila con punteggi non commensurabili — BM25 pesa la lunghezza, il denso soffre l'asimmetria di granularità — così che la composizione del result set dipenderebbe da artefatti di lunghezza più che dal contenuto. Con indici distinti ogni ecosistema è interrogato al suo interno e i due result set sono confrontabili come campioni omogenei.

3.4 Scelte di progettazione e alternative scartate

La Tabella 3.1 raccoglie le decisioni rilevanti, ciascuna con l'alternativa considerata e la ragione dello scarto.

Decisione	**Alternativa scartata**	**Motivazione**
Retrieval ibrido sparso + denso	Solo denso, oppure solo BM25	Complementari: BM25 cattura i termini tecnici esatti ("PWR reactor", "CO_2 ppm"), il denso sinonimi e parafrasi del dibattito argomentativo. Presi singolarmente lasciano scoperte classi di query complementari (verificato empiricamente, §7.4).
Indice FAISS esatto	Indice approssimato (HNSW, IVF)	Su 10^3–10^4 vettori il vantaggio di latenza è irrilevante, mentre l'esattezza garantisce riproducibilità perfetta.
Un indice per (tema × ecosistema)	Indice unico globale	L'utente interroga un tema specifico; indici separati evitano il rumore cross-tema e sono il prerequisito del confronto fra ecosistemi.
Bilanciamento deterministico delle colonne	Loop agentico con LLM orchestratore	Il riempimento ordinato è $O(n)$, deterministico e ispezionabile. Un loop agentico introdurrebbe non-determinismo e costo senza garanzie aggiuntive.
Full fine-tuning di DeBERTa-v3-base	Mixture-of-Experts; DANN; LoRA	MoE introduce non-determinismo nel routing, rendendo la Macro-F1 non riproducibile su test fisso. DANN aggiunge complessità di addestramento non giustificata quando la generalizzazione si ottiene a monte tramite VAST. Il modello è piccolo (184M) e sta nei 6 GB in fp16.
Diversità calcolata sul pool	Diversità sulle colonne mostrate	Le colonne sono bilanciate per costruzione: misurarne l'entropia restituirebbe una costante travestita da misura.
Fact-checking su KB locale	API di ricerca web o servizi cloud	Riproducibilità (la KB è congelata e versionata per hash), assenza di quote e costi, funzionamento offline. Il prezzo è la copertura limitata, dichiarata fra i limiti.
Due motori di verdetto sullo stesso stack	Due sistemi di fact-checking distinti	Condividendo estrazione, recupero e cancello di pertinenza, l'unica variabile che cambia è il motore: la differenza misurata è attribuibile ad esso.
Beam search deterministico	Sampling con temperatura	La riproducibilità richiede che lo stesso cluster produca sempre lo stesso riassunto. Con `do_sample=False` la temperatura è ininfluente: usarla sarebbe una contraddizione tecnica.

Tabella 3.1: Decisioni architetturali, alternative considerate e motivazioni.

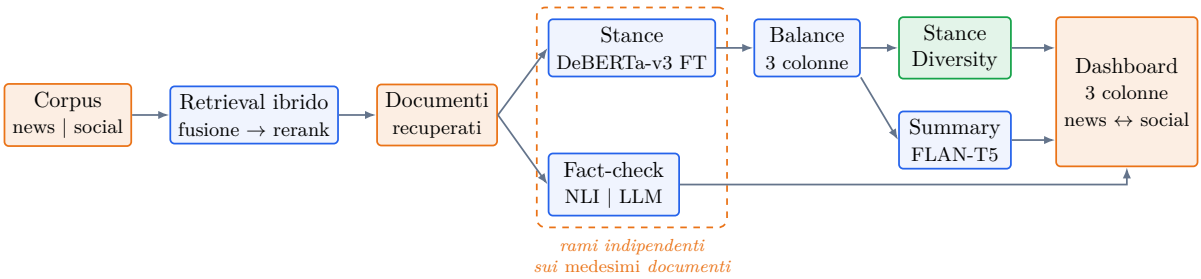


Figura 3.1: Architettura del sistema. **Stance** e **fact-check** operano entrambi sui documenti recuperati, in modo reciprocamente indipendente; **balance** consuma le stance e **summary** le colonne bilanciate. Il fact-check non alimenta il riassunto: arricchisce i documenti mostrati.

3.5 Il vincolo hardware come vincolo di progetto

L'intero sistema è progettato per una GPU portatile da **6 GB** (NVIDIA RTX 4050 Laptop). Far coesistere un bi-encoder, un cross-encoder, un classificatore di stance, un modello NLI, un modello generativo e — nel percorso LLM — un modello da 7 miliardi di parametri richiede misure esplicite:

- **Caricamento pigro**: nessun modello è istanziato nel costruttore; ogni componente pesante è una *property* caricata al primo uso. Una ricerca senza fact-checking né riassunti non carica mai spaCy, l'NLI o FLAN-T5. Il beneficio collaterale è la testabilità della logica pura senza scaricare gigabyte di pesi.
- **Cache a voce singola**: cambiare tema *sostituisce* l'applicazione caricata anziché affiancarne una seconda.
- **Allocatore a segmenti espandibili** e liberazione esplicita della cache CUDA fra i due ecosistemi, per contenere la frammentazione — causa più frequente di esaurimento apparente quando si alternano modelli di dimensioni diverse.
- **Parametri ridotti nel solo percorso interattivo** (batch, claim per documento, beam): degradazione consapevole di qualità in cambio di latenza. Non è applicata al percorso di valutazione, quindi i numeri del Capitolo 7 non sono ottenuti con la configurazione ridotta.

Il vincolo ha avuto un effetto in parte benefico sulla qualità metodologica: ha reso impraticabile l'accumulo indiscriminato di modelli sempre più grandi e ha imposto di verificare, per ogni componente, se un modello maggiore valesse il suo costo — l'ablazione base vs large sul motore NLI (§7.2) nasce da questa necessità.

3.6 Organizzazione del codice

Il codice è organizzato per responsabilità: `preprocessing`, `retrieval` (sparse, dense, hybrid, reranker, column_balancer), `nlp` (stance, fact-checker nelle sue varianti, summarizer), `evaluation` (metriche e caricamento dei qrels), `gui`. Gli script di costruzione dei dati e di valutazione stanno in `scripts/`, separati dal codice di libreria perché hanno dipendenze più pesanti e non devono essere importati dalla pipeline online.

Tutti gli iperparametri risiedono in `configs/config.yaml`, con la motivazione di ciascuno annotata accanto al valore; due file ausiliari definiscono temi, target e query canoniche

(`topics.yaml`) e il registro di credibilità delle fonti (`sources.yaml`). Vi risiedono anche le tre soglie del fact-checker — il cancello di pertinenza e le due soglie asimmetriche del verdetto — che sono scelte sperimentali e come tali devono essere visibili e modificabili senza toccare il codice.

Una convenzione che si è rivelata utile è la separazione sistematica fra **funzioni pure** e codice di I/O negli script: nella costruzione del corpus social, per esempio, parsing, campionamento e costruzione dei documenti sono funzioni pure, e solo `main()` accede a rete e filesystem. Il beneficio è la testabilità: la suite conta **174 test** eseguiti in meno di 30 secondi, senza rete e senza GPU, e copre preprocessing, costruzione dei dati, aggregazione dei verdetti, parsing delle risposte LLM, rendering della GUI, metriche di ranking, κ e Stance Diversity.

3.7 Interfaccia

La dashboard (Streamlit) traduce le scelte metodologiche in scelte di presentazione: tre colonne affiancate con palette divergente; una barra di diversità segmentata che mostra contemporaneamente il punteggio e le proporzioni del pool; schede per ecosistema, così che il confronto sia un cambio di scheda a parità di tutto il resto; card espandibili con claim, verdetto e collegamenti alle fonti. Il *soft-filter* merita una nota: selezionando una posizione la colonna corrispondente si allarga, ma le altre *non* scompaiono — un filtro rigido ricostruirebbe esattamente l'echo chamber che il sistema intende contrastare.

Le query canoniche sono **precalcolate**: corpus fisso e modelli deterministici implicano che i risultati non cambino, quindi si calcolano una volta e si rileggono da JSON in millisecondi, senza GPU a runtime. La motivazione è pratica: il fact-checking con motore LLM richiede minuti per ecosistema, il che lo renderebbe inadatto a una dimostrazione interattiva.

4. Dati

Questo capitolo documenta i dati impiegati. Riceve spazio ampio perché è dove nascono contemporaneamente i risultati del lavoro e i loro limiti: le decisioni di campionamento prese qui determinano che cosa i numeri del Capitolo 7 possano dimostrare.

4.1 Temi e target

Sono stati selezionati tre temi divisivi: energia nucleare, cambiamento climatico, vaccini. Per ciascuno sono definiti parole chiave per il filtraggio, un *target* per la stance detection e un insieme di query canoniche (Tabella 4.1).

La distinzione fra *tema* e *target* merita attenzione, perché è una delle poche scelte tarate empiricamente. Il target è la stringa passata allo stance detector come primo segmento della coppia, e la sua formulazione influenza il comportamento del classificatore. Due decisioni sono state prese su misure e non su intuizioni. Per il clima si usa `"global warming"` anziché `"climate change"`: il primo è più *marcato*, dato che nel dibattito anglosassone "climate change" è divenuto largamente descrittivo mentre "global warming" conserva la carica polemica delle posizioni negazioniste; la sostituzione ha portato il recall su AGAINST dal 51% al 78%. Per i vaccini si usa il target generale `"vaccine safety"` anziché `"COVID-19 vaccination"`: quest'ultimo produceva una diversità sul corpus news implausibilmente alta (0,69, superiore a quella del social) senza alcun miglioramento del recall su AGAINST.

Il secondo caso è metodologicamente istruttivo: un target mal scelto può *gonfiare* la metrica di diversità senza che nulla sia migliorato. È un promemoria del fatto che la Stance Diversity è una misura derivata, la cui affidabilità non supera quella del classificatore che la alimenta.

L'ultima query dei vaccini è inclusa deliberatamente come banco di prova del fact-checker: verte su una claim falsa notoria di cui la knowledge base contiene la confutazione esplicita.

4.2 Corpus news: CC-News

L'ecosistema media/news è costruito da **CC-News** (`vblagoje/cc_news`), consumato in streaming. Ogni articolo attraversa una catena di filtri: lunghezza minima (i frammenti troncati non hanno contenuto argomentativo); un filtro anti-spam commerciale; l'assegnazione del tema per *densità* di parole chiave, dove un articolo è accettato solo se supera contemporaneamente una soglia sul numero di occorrenze e una sulla loro densità — la seconda è essenziale, perché un articolo di tremila parole che cita "climate change" una volta di passaggio non è un articolo sul clima; e infine un **tetto del 15% per dominio**, senza il quale le agenzie ad alto volume saturerebbero il corpus, con il duplice danno di ridurne artificialmente la diversità e di sovrarappresentare articoli quasi duplicati.

Due osservazioni sulla Tabella 4.2. Il tema nucleare non raggiunge la quota di 800 documenti: la finestra temporale di CC-News non contiene abbastanza articoli che superino congiuntamente le soglie di densità e il tetto per dominio. La colonna *Tier* indica invece che la maggioranza dei documenti ricade nel tier 3, che è il valore *prudenziale di default* assegnato ai domini non

Tema	Target	Ecosistemi	Query canoniche
Nucleare	`nuclear energy`	news	*risks of nuclear energy*; *is nuclear power safe*; *nuclear energy and climate change*; *nuclear waste disposal*
Clima	`global warming`	news, social	*is climate change caused by humans*; *economic cost of climate policy*; *climate change and extreme weather*
Vaccini	`vaccine safety`	news, social	*are vaccines safe*; *vaccine side effects*; *vaccine mandates*; *do vaccines cause autism*

Tabella 4.1: Temi, target di stance, ecosistemi disponibili e query canoniche.

Tema	Doc.	Tier 2	Tier 3	Domini più frequenti
Nucleare	403	38	365	uk.reuters.com (46), reuters.com (19), dailymail.co.uk (13)
Clima	800	49	751	uk.reuters.com (79), eurekalert.org (30), channelnewsasia.com (28)
Vaccini	714	53	661	nbcnews.com (19), dailymail.co.uk (15), uk.reuters.com (13)
Totale	**1917**	**140**	**1777**	

Tabella 4.2: Composizione del corpus news dopo il filtraggio (708 241 articoli scansionati).

presenti nel registro delle fonti: non significa che il corpus sia di bassa qualità, ma che il registro copre una frazione minoritaria dei domini presenti.

Un dato rilevante per l'interpretazione. Una misura condotta sul corpus news con il modello di stance fine-tunato rileva che i documenti classificati AGAINST costituiscono il 2,6% del corpus clima e il 2,9% del corpus vaccini. In positivo, è una misura diretta e non confondata dell'omogeneità del corpus news: la cronaca su questi temi, nel campione considerato, quasi non contiene posizioni contrarie. In negativo, è precisamente ciò che ha reso necessaria la costruzione di un corpus social con campionamento stratificato — e che ha così generato il confondimento discusso nella sezione seguente.

4.3 Corpus social

L'ecosistema social utilizza due dataset pubblici di tweet etichettati per stance, scaricati direttamente da repository GitHub senza alcun ricorso alle API di Twitter (che oggi non sarebbero né gratuite né riproducibili):

Clima

`edwardcqian/climate_change_sentiment`, file `data/sample_data.csv`.
Campo testuale `message`, etichetta `sentiment`, mappatura $\{1 \to$ FAVOR, $-1 \to$ AGAINST, $0 \to$ NEUTRAL$\}$; la classe "2" (segnalazione di notizia) è scartata perché non esprime una posizione.

Vaccini

`sohampoddar26/covid-vax-stance`, file `dataset/our_labelled_data.csv`.
Campo testuale `tweet`, etichetta `majority_label`, mappatura {ProVax $\to$ FAVOR, AntiVax $\to$ AGAINST, Neutral $\to$ NEUTRAL}.

Gli URL esatti, i conteggi e l'hash SHA-256 dei file prodotti sono in `data/corpora/MANIFEST_social.json`. Il trattamento comprende deduplicazione per testo normalizzato (necessaria per eliminare i retweet, che gonfierebbero le classi più virali) e campionamento

Split	Esempi	FAVOR	AGAINST	NEUTRAL	VAST	SemEval	Target
Train	16 097	6 005	6 849	3 243	13 477	2 620	4 644
Test	4 255	1 248	1 733	1 274	3 006	1 249	763

Tabella 4.3: Composizione degli split per la stance detection.

stratificato per classe con tetto uniforme e seed fissato: 999 tweet per il clima (333 per classe) e 870 per i vaccini (290 per classe).

Avvertenza metodologica — confondimento fra ecosistema e campionamento.
Il corpus social ha, *per costruzione*, entropia di stance massima (1,000): le tre classi sono campionate in parti esattamente uguali. Il corpus news ha invece la distribuzione *naturale* risultante dal filtraggio, fortemente sbilanciata (circa il 3% di AGAINST). Ne consegue che il confronto diretto fra la diversità misurata sui due ecosistemi **non isola una proprietà degli ecosistemi**: una parte non quantificabile a priori della differenza osservata è attribuibile alla differenza fra un campionamento stratificato e uno naturale.

La stratificazione non è stata arbitraria: senza di essa non sarebbe stato possibile disporre di un gold set bilanciato su cui valutare lo stance detector nella classe AGAINST — valutazione che si è rivelata uno dei risultati diagnostici più informativi del progetto. In altri termini, la stratificazione era la scelta giusta per l'obiettivo di *valutare lo stance detector* ed è quella sbagliata per l'obiettivo di *confrontare gli ecosistemi*; il corpus è stato costruito una volta e usato per entrambi gli scopi, e questo è l'errore di disegno. La contromisura proposta è nella Sezione 5.5.

4.4 Knowledge base, dataset di stance e benchmark

La fonte di evidenza del fact-checker è una **knowledge base Wikipedia** di 1589 articoli, costruita espandendo categorie seme pertinenti ai tre temi — incluse deliberatamente *Climate change denial* e *Vaccine hesitancy*, perché la KB deve contenere le voci che descrivono e confutano le posizioni negazioniste, altrimenti il fact-checker non troverebbe evidenze proprio per le claim che più contano. Di ciascun articolo si scarica l'**introduzione** anziché il testo completo: per convenzione redazionale è un riassunto dei fatti salienti, quindi la porzione a più alta densità di evidenza verificabile. L'accesso avviene via API MediaWiki con *batching* e User-Agent conforme; ogni evidenza conserva titolo e URL canonico, il che rende ogni verdetto tracciabile dall'interfaccia.

Il modello di stance è addestrato sull'unione di **VAST** [18] e **SemEval-2016 Task 6** [16], normalizzati in uno schema comune (Tabella 4.3). Due caratteristiche vanno sottolineate: l'elevatissimo numero di **target distinti** in addestramento (4 644, interamente dovuto a VAST), che è la proprietà da cui deriva la capacità di generalizzare a temi non visti; e lo **sbilanciamento di NEUTRAL** (20,1% contro il 42,5% di AGAINST), che motiva l'uso della Macro-F1 come metrica di selezione del modello.

La valutazione del fact-checking impiega **ClimateFEVER** [6]. Ogni claim è corredata di più evidenze con etichetta propria, oltre all'etichetta complessiva: la doppia annotazione consente la valutazione a due granularità descritta nella Sezione 6.4. Le claim DISPUTED sono escluse

dalla valutazione a livello di claim, poiché il sistema non prevede una classe corrispondente e includerle significherebbe conteggiare come errori casi in cui nessuna risposta disponibile è corretta.

4.5 Riproducibilità dei dati

Ogni fase di costruzione produce un `MANIFEST.json` che registra sorgente esatta, parametri, conteggi, distribuzione per classe e un **hash SHA-256** del file prodotto. I file di dati non sono versionati — sono rigenerabili — mentre i manifest lo sono: chiunque rieseguga uno script può verificare l'identità bit a bit del proprio risultato con quello usato qui. Tutti i campionamenti usano un seed esplicito.

5. Metodologia

5.1 Preprocessing

Il preprocessing serve esclusivamente al ramo sparso: il ramo denso opera sul testo grezzo, perché i modelli di embedding sono addestrati su testo naturale. Tre scelte lo caratterizzano. La **lemmatizzazione** anziché lo stemming, che produce forme troncate spesso non parole, scelta anche perché le frasi del corpus vengono mostrate all'utente come anteprime ed evidenze. La **preservazione delle negazioni** (`not`, `never`, `n't` e una lista estesa), benché figurino nelle liste standard di stopword: "Nuclear power is *not* safe" e "Nuclear power is safe" hanno stance opposte e token quasi identici una volta rimosse. E la **simmetria** fra documenti in indicizzazione e query in interrogazione: un'asimmetria è sorgente classica di *vocabulary mismatch* artificiale.

5.2 Retrieval, stadio 1: fusione

Ramo sparso. BM25 (Equazione 2.1) con $k_1 = 1{,}2$, valore di default standard adottato da Lucene ed Elasticsearch, e $b = 0{,}60$, deliberatamente inferiore al default 0,75. La ragione è di dominio: la normalizzazione per lunghezza esiste per contrastare un effetto spurio — un documento lungo contiene più termini e ha più probabilità di contenere quelli della query per caso — ma su una collezione omogenea di articoli giornalistici, dove quasi tutti i documenti sono lunghi, l'effetto spurio è minore mentre il costo resta: penalizzare i documenti lunghi significa penalizzare gli articoli più ricchi di evidenze fattuali, che sono quelli di cui il fact-checking a valle ha bisogno.

Ramo denso. I documenti sono segmentati in *chunk* da 512 token con overlap di 128 (25%). Il valore 512 corrisponde al limite del contesto degli encoder BERT-based: un testo più lungo verrebbe silenziosamente troncato dall'encoder. L'overlap del 25% — coerente con la pratica di Lewis et al. [13] — evita che un'affermazione a cavallo di due chunk vada perduta da entrambi. L'implementazione opera a livello di parola con un fattore di conversione stimato, approssimazione dichiarata. Ogni chunk è codificato con *bge-base-en-v1.5* (768 dim.), L2-normalizzato e inserito in un indice FAISS `IndexFlatIP`; la query è codificata con il prefisso-istruzione, i passaggi mai.

Poiché l'unità indicizzata è il chunk ma quella restituita è il documento, serve un'aggregazione. Si adotta il **max-pooling**:

$$\text{dense}(d) = \max_{c \in \text{chunk}(d)} \text{sim}(q, c). \tag{5.1}$$

La motivazione è che un documento è rilevante se *almeno una* sua porzione lo è: un articolo che dedica un paragrafo esattamente al tema della query è rilevante anche se i restanti nove decimi parlano d'altro. Una media penalizzerebbe sistematicamente i documenti lunghi, reintroducendo dal lato denso la distorsione che dal lato sparso si è attenuata abbassando b.

Normalizzazione e fusione. Entrambi i rami producono un punteggio per *ogni* documento. I due vettori sono normalizzati min-max in $[0, 1]$ e combinati secondo l'Equazione 2.2 con $\alpha = 0{,}45$

Parametro	Valore	Parametro	Valore
Modello base	`deberta-v3-base`	Warmup ratio	0,06
Lunghezza massima	256 token	Weight decay	0,01
Epoche	3 (early stopping, patience 1)	Precisione	fp16
Batch size	8 ($\times$4 accumulation = 32)	Metrica di selezione	Macro-F1 val.
Learning rate	2×10^{-5}	Validazione	10%, stratificata

Tabella 5.1: Iperparametri di fine-tuning dello stance detector (seed 42).

e $\beta = 0{,}55$. La normalizzazione è indispensabile perché BM25 non è limitato superiormente mentre il coseno vive in $[-1, 1]$: sommarli grezzi equivarrebbe a ignorare il ramo denso. La scelta $\alpha < \beta$ riflette la natura semantica del dominio, mantenendo però un peso sostanziale al segnale lessicale, perché la terminologia tecnica specifica è proprio ciò che i modelli densi tendono a generalizzare eccessivamente. La selezione dei primi k avviene *una sola volta* sui punteggi fusi, ottenendo un pool di 50 documenti; è implementata anche la baseline RRF (Equazione 2.3). Se l'indice denso non è disponibile il sistema degrada a solo-BM25 con un avviso, anziché fallire.

5.3 Retrieval, stadio 2: reranking

Il pool viene riordinato da un cross-encoder (*bge-reranker-base*) che ripunteggia i primi 30 candidati: il flusso è un imbuto $|\mathcal{D}| \to 50 \to 30$. Due precisazioni. Il reranker è **agnostico alla stance**: riordina per pura pertinenza, e il bilanciamento avviene interamente dopo. Mescolare i due criteri renderebbe impossibile distinguere, nel risultato finale, ciò che è stato scelto per pertinenza da ciò che è stato scelto per bilanciamento, e soprattutto renderebbe circolare la misura di diversità. Inoltre il reranker non può recuperare ciò che lo stadio 1 non ha proposto: il suo tetto è il recall dello stadio 1, ed è questa la ragione per cui il Recall@k è la metrica corretta per valutare il primo stadio e l'NDCG@10 quella per la pipeline completa.

5.4 Stance detection

Dato un target t e un documento d il modulo stima $P(s \mid t, d)$ su tre classi, restituendo la classe di massima probabilità, la sua confidenza e la distribuzione completa — conservata e propagata fino all'interfaccia, così che l'utente possa distinguere una classificazione netta da una incerta.

Il modello è un **DeBERTa-v3-base** [8] (184M) sottoposto a *full fine-tuning* su VAST $\cup$ SemEval, con input codificato come coppia nativa `[CLS] target [SEP] documento [SEP]`. Gli iperparametri sono nella Tabella 5.1; due meritano un commento. La selezione del checkpoint su **Macro-F1 di validazione** anziché sulla loss: con classi sbilanciate la loss è dominata dalle maggioritarie, e selezionare su di essa produrrebbe modelli che sacrificano NEUTRAL. E la combinazione *batch size* 8 con *gradient accumulation* 4, che realizza un batch efficace di 32 restando entro i 6 GB: la traduzione diretta del vincolo hardware in una scelta di addestramento.

In inferenza i documenti sono troncati alle prime 400 parole ($\approx$512 token). Il troncamento privilegia l'inizio dell'articolo, scelta ragionevole nel dominio giornalistico dove la struttura a piramide rovesciata colloca in apertura la tesi principale, ma va dichiarata: un articolo che esprime la propria posizione solo in chiusura verrebbe classificato sulla sua parte descrittiva. Se

il modello fine-tunato non è presente su disco il sistema degrada a una pipeline *zero-shot* su modello NLI, che è anche la **baseline** contro cui il fine-tuning è misurato.

5.5 Bilanciamento e Stance Diversity

I documenti rerankati sono classificati e distribuiti nelle tre colonne con un algoritmo deliberatamente elementare e deterministico:

```
classifica tutti i documenti del pool (un solo batch)
per ogni documento d, in ordine di pertinenza decrescente:
    c = stance(d)
    aggiungi d a full[c]                  # tutto il pool: serve alla diversity
    se len(colonne[c]) < per_column:      # per_column = 5
        aggiungi d a colonne[c]           # le colonne prendono i piu' pertinenti
diversity = entropia_normalizzata(full)
```

Poiché il pool è già ordinato per pertinenza, il primo documento di una data posizione è anche il più pertinente di quella posizione: le colonne raccolgono i migliori rappresentanti di ciascuna fazione senza ordinamenti aggiuntivi. Se una posizione è rara l'algoritmo la pesca scorrendo più in profondità; se è assente la colonna resta vuota, e questa è un'informazione, non un difetto. È la versione deterministica dell'idea di *self-correction retrieval*: nessun loop agentico, solo una selezione ordinata $O(n)$ ispezionabile.

La diversità è l'entropia di Shannon normalizzata sulla distribuzione delle stance:

$$\text{Diversity}(p) = -\frac{1}{\log 3} \sum_{c \in \{\text{F,N,A}\}} p_c \log p_c \ \in \ [0, 1], \tag{5.2}$$

con la convenzione $0 \log 0 = 0$.

Perché sul pool e non sulle colonne. La diversità è calcolata sulla distribuzione dell'**intero pool classificato**, non sulle tre colonne mostrate. Le colonne sono bilanciate *per costruzione*: se il pool contiene almeno cinque documenti per posizione, le colonne conterranno 5+5+5 e la loro entropia sarà esattamente 1, indipendentemente da qualunque proprietà del corpus. Misurare lì restituirebbe una costante travestita da misura. Ne segue la lettura dei due numeri che l'interfaccia mostra affiancati: la barra rappresenta *ciò che il corpus offre*, le colonne *ciò che il sistema mostra*, e la distanza fra i due è la misura di quanto il bilanciamento sia intervenuto.

Proprietà e limiti. La metrica vale 0 se e solo se tutti i documenti condividono la stessa posizione e 1 se e solo se le tre sono equamente rappresentate (Tabella 5.2). È *invariante per permutazione* delle classi: un pool dominato da NEUTRAL riceve lo stesso punteggio di uno dominato da FAVOR, benché il primo descriva una copertura descrittiva e il secondo una schierata — per questo l'interfaccia mostra sempre anche la distribuzione. È *insensibile alla dimensione* del campione, desiderabile per la confrontabilità ma con la conseguenza che la metrica non segnala la propria incertezza: su pool di 30 documenti la varianza campionaria non è trascurabile. Ed è calcolata su etichette *predette*: un classificatore che confonde le classi tende a produrre distribuzioni più uniformi di quelle reali, gonfiando la diversità. È la minaccia principale (§8.3.1).

Distribuzione (F, N, A)	Proporzioni	Diversity	Lettura
$(30, 0, 0)$	(1,00; 0; 0)	0,00	echo chamber perfetta
$(28, 1, 1)$	(0,93; 0,03; 0,03)	0,27	copertura quasi unanime
$(20, 8, 2)$	(0,67; 0,27; 0,07)	0,73	dominante, minoranza presente
$(15, 10, 5)$	(0,50; 0,33; 0,17)	0,92	dibattito sbilanciato ma reale
$(10, 10, 10)$	(0,33; 0,33; 0,33)	1,00	bilanciamento perfetto

Tabella 5.2: Comportamento della Stance Diversity su un pool di 30 documenti.

Una metrica correttiva: il diversity lift. Come anticipato, il confronto diretto fra le diversità di due corpora campionati diversamente non isola una proprietà degli ecosistemi. Sia p_q^{pool} la distribuzione nel pool per la query q e p^{corpus} quella dell'intero corpus; si definisce

$$\text{Lift}(q) = \frac{H(p_q^{\text{pool}})}{H(p^{\text{corpus}})}. \tag{5.3}$$

Il lift risponde a una domanda migliore: *il retrieval amplifica o attenua lo sbilanciamento già presente nel corpus?* Un valore > 1 indica che il sistema recupera un insieme più plurale del corpus medio; un valore < 1 che il ranking per pertinenza sta concentrando le prospettive, cioè che il motore stesso contribuisce all'echo chamber. Il pregio decisivo è di essere **invariante rispetto alla distribuzione a priori**: due corpora campionati diversamente producono lift confrontabili. Il calcolo richiede una passata batch dello stance detector sull'intero corpus; l'implementazione è indicata fra gli sviluppi immediati.

5.6 Fact-checking

Il fact-checker realizza l'architettura a tre fasi di FEVER con una scelta distintiva: le prime due fasi sono condivise, la terza è *intercambiabile*.

Fase 1 — estrazione delle claim. Dal testo si estraggono le frasi dichiarative con predicato verbale tramite spaCy. Non tutte meritano verifica: si adotta un'euristica di *check-worthiness* ispirata a ClaimBuster [5] che pesa le frasi su entità nominate e valori numerici, con peso maggiore alle entità — una claim verificabile cita tipicamente fatti concreti e attribuiti ("*France* generates *70%* of its electricity from nuclear power"), mentre una percentuale isolata senza soggetto è ambigua. In esercizio si verifica la claim più check-worthy di ciascun documento mostrato, limitazione dettata dal costo.

Fase 2 — evidenze e cancello di pertinenza. Le frasi della KB sono codificate con *bge* e la ricerca avviene per similarità coseno. Il componente critico è il **cancello di pertinenza**: se la similarità della migliore evidenza è inferiore a 0,62 il verdetto è immediatamente NOT_ENOUGH_EVIDENCE e il motore non viene nemmeno invocato. L'accorgimento è meno banale di quanto sembri e nasce da un'osservazione empirica: un recupero semantico su una KB tematica restituisce *sempre* qualcosa, e passare al motore un'evidenza solo tematicamente vicina produce un'alta percentuale di falsi REFUTED, perché il modello NLI legge come

contraddizione una premessa che parla d'altro pur nello stesso ambito. Il cancello trasforma questo fallimento silenzioso in un onesto "non ho evidenze sufficienti".

Fase 3a — motore NLI. Un classificatore FEVER-tuned (`DeBERTa-v3-base-mnli-fever-anli`) predice per ciascuna coppia (evidenza, claim) le probabilità di entailment, neutralità e contraddizione. La regola di decisione è deliberatamente *asimmetrica*:

$$\text{verdetto} = \begin{cases} \textsc{supported} & \text{se } \max_i P_{\text{ent}}^{(i)} \geq 0{,}75 \ \wedge \ \max_i P_{\text{ent}}^{(i)} \geq \max_i P_{\text{con}}^{(i)}, \\ \textsc{refuted} & \text{se } \max_i P_{\text{con}}^{(i)} \geq 0{,}95, \\ \textsc{nei} & \text{altrimenti.} \end{cases} \tag{5.4}$$

L'asimmetria fra le due soglie riflette un giudizio sui costi d'errore: dichiarare falsamente "confutata" un'affermazione vera è, in un sistema che si presenta come strumento di verifica, molto più grave del dichiarare "evidenza insufficiente" — il primo produce disinformazione con l'autorità del sistema, il secondo solo un'astensione. Gli indici delle classi sono letti dinamicamente da `model.config.id2label`, non hardcodati: un errore silenzioso classico se si sostituisce il modello NLI con uno che ordina le classi diversamente.

Fase 3b — motore LLM. Un Large Language Model locale (`qwen2.5:7b` via Ollama) ragiona sull'insieme delle evidenze e restituisce un verdetto strutturato in JSON con motivazione (prompt in Appendice B). Tre aspetti sono rilevanti. Il **grounding puro**: il prompt istruisce il modello a giudicare esclusivamente sulle evidenze fornite, mai sulla conoscenza parametrica. Il vincolo riduce le allucinazioni e — soprattutto — rende il confronto con l'NLI onesto: senza grounding, un'eventuale superiorità dell'LLM sarebbe attribuibile alla conoscenza pregressa anziché alla capacità di ragionare sull'evidenza, rendendo il confronto privo di significato. Il **determinismo**: temperatura 0 e output vincolato a JSON. E la **robustezza del parsing**: funzioni pure e testabili senza rete che tentano il JSON, in caso di fallimento cercano un'etichetta riconoscibile nel testo, normalizzano un'ampia tabella di sinonimi che i modelli producono spontaneamente, e in assenza di segnale ripiegano su NOT_ENOUGH_EVIDENCE. Anche l'irraggiungibilità del server produce NEI anziché un'eccezione: il fallimento è *sicuro* per costruzione.

5.7 Summarization

La sintesi per prospettiva impiega FLAN-T5-base con strategia *extract-then-abstract*: una fase estrattiva punteggia le frasi della colonna con un BM25 a livello di frase e ne seleziona le più salienti, riducendo l'input sotto la finestra di contesto e insieme la ridondanza fra documenti che riportano gli stessi fatti. La fase astrattiva usa **beam search puro** (`do_sample=False`, `no_repeat_ngram_size` = 3): lo stesso cluster deve produrre sempre lo stesso riassunto. Si segnala una precisazione tecnica fonte di confusione frequente: la temperatura ha effetto *solo* quando il campionamento è attivo, e associarla al beam search è una combinazione incoerente, non una regolazione della creatività.

Una nota di onestà implementativa: era stata sperimentata l'iniezione di marcatori di riferimento (`[Doc N]`) per rendere ogni affermazione tracciabile, e la tecnica è stata *abbandonata* perché FLAN-T5-base riproduce i marcatori come stringhe senza usarli correttamente, producendo attribuzioni errate — peggio dell'assenza di attribuzione. La tracciabilità è garantita a livello di colonna. Il modulo non è stato fine-tunato per l'assenza di riassunti di riferimento di dominio e perché la strategia estrattiva riduce il compito generativo alla sola riscrittura.

6. Protocollo sperimentale

Questo capitolo definisce che cosa viene misurato, come e su quali dati, *prima* di riportarne i risultati. La separazione non è formale: serve a rendere verificabile che le metriche non siano state scelte dopo aver visto i numeri.

6.1 Principi e ambiente

Il protocollo segue quattro principi: **benchmark citabili** dove possibile (VAST, SemEval-2016 T6, ClimateFEVER) anziché dati costruiti ad hoc; **separazione degli insiemi**, con selezione del checkpoint sulla validazione e mai sul test; **isolamento della variabile**, cioè nei confronti fra alternative cambia un solo elemento; e **dichiarazione delle lacune**, elencate esplicitamente anziché omesse.

Tutte le valutazioni sono offline, su GPU NVIDIA RTX 4050 Laptop da 6 GB. Nessuna misura dipende da servizi remoti, quote o chiavi API; l'LLM è eseguito in locale. I comandi esatti sono in Appendice D.

6.2 Metriche

Accuracy è riportata per completezza ma non è la metrica primaria: su classi sbilanciate premia i classificatori che ignorano le classi rare. La metrica primaria per stance e fact-checking è la **Macro-F1**, media *non pesata* delle F1 per classe: non pesando le classi per frequenza, attribuisce a una classe rara e difficile lo stesso peso di una frequente, così che un modello che ignorasse NEUTRAL, o che non emettesse mai SUPPORTED, venga penalizzato in modo visibile. Poiché entrambi questi comportamenti si sono effettivamente manifestati, la scelta si è rivelata diagnosticamente decisiva; le F1 per classe sono sempre riportate accanto alla media, perché la media da sola può nascondere profili molto diversi.

Per il ranking si usano NDCG@k (Equazione 2.4), MAP e Recall@k; per la diversità l'entropia normalizzata (Equazione 5.2); per l'accordo fra annotatori il κ di Cohen [7], nella variante a **pesi quadratici** $w_{ij} = 1 - ((i-j)/(K-1))^2$, che è quella corretta su scala ordinale: la versione non pesata tratterebbe "0 contro 1" e "0 contro 2" come lo stesso errore.

6.3 Protocollo: stance detection

Tre livelli di difficoltà e rilevanza applicativa crescenti. **Test held-out**: Macro-F1 e F1 per classe sui 4 255 esempi di test, confrontate con la baseline zero-shot NLI sugli stessi esempi. **Cross-dataset**: le stesse metriche calcolate *separatamente* sui due sottoinsiemi di provenienza, per verificare che la prestazione complessiva non sia trainata da un solo dataset e che il modello generalizzi a target non visti. **Dominio applicativo**: Macro-F1 sulle etichette gold dei corpora social, la misura più severa perché valuta il modello fuori distribuzione, ed è anche l'unica condotta sui dati effettivamente elaborati in esercizio.

Va dichiarato che **non** esiste una valutazione equivalente per l'ecosistema news: mancano etichette gold su articoli. La conseguenza per l'interpretazione della diversità è nella Sezione 8.3.1.

6.4 Protocollo: fact-checking

La valutazione su ClimateFEVER è condotta a **due granularità** che misurano cose diverse. *Per-evidenza*: il motore predice l'etichetta di ogni coppia (claim, evidenza) e la si confronta con l'etichetta della singola evidenza; è la misura pulita del motore come classificatore, senza aggregazione. *Claim-level*: il verdetto è ottenuto aggregando su tutte le evidenze della claim e confrontato con l'etichetta complessiva; è il verdetto end-to-end, più difficile perché somma all'errore di classificazione quello di aggregazione.

Il confronto fra motori è condotto a livello di claim e **a parità di evidenze**: a entrambi vengono passate esattamente le stesse evidenze annotate del benchmark, così che l'unica differenza sia il meccanismo che emette il verdetto. È il punto metodologico centrale: senza di esso una eventuale superiorità dell'LLM sarebbe attribuibile in modo indistinguibile al motore o alla catena di recupero. È inoltre prevista un'**ablazione** sulla dimensione del modello NLI (*base* contro *large*), per verificare se il costo superiore sia giustificato.

6.5 Protocollo: Stance Diversity

Per ciascun tema si eseguono le query canoniche su tutti gli ecosistemi disponibili, si registra la diversità del pool per ogni coppia (query, ecosistema) e si riporta la media per ecosistema. La procedura è identica per i due ecosistemi, il che elimina per costruzione i confondimenti di trattamento. Resta il confondimento di campionamento della Sezione 4.3, che il protocollo attuale *non* controlla; il protocollo esteso prevede di riportare accanto a ciascuna diversità anche quella a priori del corpus e il *diversity lift*.

6.6 Protocollo: retrieval

Topic e pooling. Le 11 query canoniche. Per ciascuna il pool è l'**unione** dei primi 20 risultati di cinque run: BM25 puro, denso puro, RRF, fusione con α di default, e l'insieme dei candidati riordinati dal reranker. I documenti mai entrati nel pool sono considerati non rilevanti, secondo la convenzione di Cranfield.

L'unione multi-run non è un formalismo. Pescando dal solo run di fusione, i documenti che esclusivamente BM25 o il denso propongono resterebbero non giudicati e conteggiati come non rilevanti, sottostimando sistematicamente proprio le baseline che l'ablazione intende confrontare — è il *pool bias*, e su un'ablazione di questo tipo ne invaliderebbe le conclusioni. La misura sui dati reali quantifica il fenomeno: dei **380** giudizi del pool, **143** — **il** 38% — **provengono da un solo run** (Tabella 6.1).

Scala e annotazione. Rilevanza graduata su tre livelli: 0 non rilevante, 1 marginalmente rilevante (tratta il tema ma non risponde alla query), 2 pienamente rilevante. La scala graduata è necessaria per l'NDCG e più informativa di quella binaria su un dominio in cui la pertinenza è raramente netta. Ogni coppia è giudicata **due volte**, da due annotatori umani che compilano fogli identici e separati: due colonne nello stesso file si contaminerebbero a vicenda e l'accordo risulterebbe gonfiato. L'ordine delle righe è randomizzato entro ciascuna query e le colonne

Tema	Query	Coppie nel pool	Da un solo run
Nucleare	4	137	50
Clima	3	109	48
Vaccini	4	134	45
Totale	**11**	**380**	**143 (38%)**

Tabella 6.1: Composizione del pool, unione di cinque run a profondità 20. L'ultima colonna quantifica ciò che un pooling dal solo run di fusione avrebbe perso.

di rango e punteggio non compaiono nel foglio: un annotatore che vede "rank 1" è primato a giudicarlo rilevante, e il *position bias* falserebbe proprio la metrica che si sta costruendo. I criteri sono formalizzati in linee guida scritte (Appendice C); la regola più rilevante — e la più facile da violare su un corpus di temi divisivi — è la separazione fra *rilevanza* e *posizione*: un documento che nega l'origine antropica del riscaldamento è pienamente rilevante per la query "*is climate change caused by humans*". Confondere i due assi significherebbe misurare il motore sulla sua capacità di occultare le opinioni scomode, cioè l'opposto dell'obiettivo del sistema.

Sistemi confrontati. Sei: BM25 puro; denso puro; RRF; fusione con α di default; fusione con α tarato; fusione seguita da reranking. Il confronto fra le prime tre e la quarta quantifica il guadagno della fusione pesata; fra la quarta e la quinta il guadagno della taratura; fra la quarta e la sesta il guadagno del secondo stadio. La taratura di α avviene in **leave-one-topic-out**: per ogni tema, α è scelto sulle query degli altri due e valutato sulle proprie. Con 11 query, scegliere α sullo stesso insieme su cui si riporta il risultato sarebbe sovradattamento garantito. Si riporta infine la **copertura dei giudizi**, cioè la frazione del top-k effettivamente giudicata: se scende sensibilmente sotto 1 il confronto è viziato dal pool e va dichiarato.

6.7 Ciò che non viene valutato

La **summarization** non è valutata quantitativamente: mancano riassunti di riferimento di dominio e in loro assenza ROUGE e BERTScore non sono calcolabili. La **stance detection sull'ecosistema news** non è valutata, per assenza di gold annotato su articoli. Il **fact-checking end-to-end sui documenti reali** non è valutato: la valutazione usa le evidenze fornite dal benchmark, quindi la qualità del recupero dalla KB propria del sistema non è quantificata. Nessuna misura è accompagnata da intervalli di confidenza o test di significatività (§8.3.4).

7. Risultati

7.1 Stance detection

Sul test held-out il modello fine-tunato raggiunge **Macro-F1** 0,771, contro 0,390 della baseline zero-shot sugli stessi esempi (Tabella 7.1).

Il guadagno è distribuito su tutte le classi ma particolarmente marcato su **NEUTRAL** (0,858 contro 0,125). Il fallimento della baseline lì è comprensibile: l'ipotesi "*This text is neutral about X*" non è una buona ipotesi NLI, perché la neutralità è l'assenza di una relazione piuttosto che una relazione, e un modello di entailment non ha modo naturale di esprimerla. La conseguenza per il sistema è diretta: senza riconoscimento affidabile di NEUTRAL la Stance Diversity sarebbe sistematicamente sovrastimata, perché i documenti neutri verrebbero distribuiti fra FAVOR e AGAINST producendo distribuzioni artificialmente bipolari. La capacità di riconoscere l'*assenza* di posizione è quindi un prerequisito della metrica, non un raffinamento.

Generalizzazione cross-dataset. Macro-F1 0,768 su VAST e 0,741 su SemEval. La sostanziale parità è positiva per due ragioni: la prestazione complessiva non è trainata dal solo dataset maggioritario, e — più rilevante — VAST contiene 763 target distinti nel test, in larga parte non visti, per cui quel valore è una misura di generalizzazione *cross-target* e non di memorizzazione. È il dato che giustifica a posteriori la rinuncia a tecniche di adattamento di dominio: la generalizzazione è stata ottenuta a monte, tramite la varietà dei target in addestramento, anziché a valle tramite l'architettura.

Dominio applicativo. Sul gold dei corpora social la Macro-F1 scende a $\sim$0,48 (clima 0,478, vaccini 0,485). Il calo, di circa 29 punti, **non è uniforme**: è quasi interamente imputabile a NEUTRAL (F1 fra 0,07 e 0,23), mentre FAVOR e AGAINST restano fra 0,6 e 0,7. Il profilo è quello di un modello che continua a distinguere bene le posizioni schierate e perde quasi completamente la capacità di riconoscere l'assenza di posizione.

L'interpretazione proposta è che il "neutro" sui social sia un **costrutto diverso**. Nei dataset di addestramento la neutralità è tipicamente un testo informativo che riporta fatti; nei tweet, molti contenuti etichettati come neutri sono ironici, allusivi, frammentari o riferiti a un contesto conversazionale assente. Non si tratta soltanto di uno spostamento di dominio linguistico ma dello spostamento della *definizione della classe*: un miglioramento richiederebbe una ri-annotazione con linee guida specifiche, non semplicemente più dati.

7.2 Fact-checking su ClimateFEVER

Motore NLI e ablazione sulla dimensione. La misura per-evidenza dà Accuracy 0,606 e Macro-F1 0,449 con il modello *base*. L'analisi per classe individua il collo di bottiglia: **SUPPORTED** ha F1 $\approx$ 0,20, contro 0,73 di NEI e 0,42 di REFUTED. Il profilo è quello di un modello *conservativo*: bravo a riconoscere l'assenza di evidenza, discreto nel confutare, debole nel confermare — e la debolezza persiste nella misura per-evidenza pura, dove le soglie del sistema non intervengono, quindi è una proprietà del modello e non della politica di decisione.

Test held-out ($n = 4255$)	**Macro-F1**	**FAVOR**	**AGAINST**	**NEUTRAL**
Fine-tuned (DeBERTa-v3-base)	**0,771**	0,715	0,740	0,858
Baseline zero-shot NLI	0,390	—	—	0,125

Tabella 7.1: Stance detection: Macro-F1 complessiva e F1 per classe.

ClimateFEVER, claim-level (n=1381)	**Acc**	**Macro-F1**	SUP	REF	NEI
NLI (DeBERTa-v3-base-mnli-fever-anli)	0,393	0,350	0,065	0,479	0,507
LLM (qwen2.5:7b, grounding puro)	**0,667**	**0,640**	**0,753**	**0,565**	**0,601**
Δ relativo	+70%	+83%	+1058%	+18%	+19%

Tabella 7.2: Fact-checking: confronto fra i due motori di verdetto a parità di evidenze.

La variante *large* dà 0,620 / 0,458: +1,4 punti di accuracy a costo circa triplo. Si adotta il modello *base*. La conclusione metodologica è però più interessante di quella operativa: che triplicare la dimensione produca meno di un punto e mezzo suggerisce che il limite non risieda nella capacità del modello ma nella *formulazione del compito* — ipotesi che l'esperimento successivo conferma.

NLI contro LLM a parità di evidenze. Sostituendo l'NLI con il ragionamento dell'LLM locale a livello di claim ($n = 1381$), i risultati cambiano radicalmente (Tabella 7.2): Macro-F1 da 0,350 a 0,640 (+83%), Accuracy da 0,393 a 0,667. Il salto decisivo è su SUPPORTED, da 0,065 a 0,753: il ragionamento colma esattamente il punto in cui l'NLI falliva.

Tre osservazioni. Il confronto è **controllato**: entrambi i motori ricevono le stesse evidenze annotate, quindi non è un confronto fra sistemi ma fra motori a parità di tutto il resto. Il **grounding esclude la spiegazione più ovvia**, cioè che l'LLM risponda a memoria su claim climatiche già viste; va detto con onestà che l'istruzione *riduce* ma non elimina formalmente il rischio, e verificarne l'assenza richiederebbe un esperimento di controllo con evidenze contraffatte, non condotto qui. E il **profilo si ribalta**: l'NLI era pessimo nel confermare e relativamente migliore nel confutare, l'LLM diventa il più forte nel confermare e trova il suo punto debole in REFUTED. Non è quindi un modello uniformemente migliore ma due profili di errore *complementari*: riconoscere una conferma richiede un'inferenza a più passi — l'evidenza raramente ripete la claim, la implica attraverso passaggi impliciti — mentre riconoscere una contraddizione è in molti casi una questione di incompatibilità locale, più alla portata di un classificatore addestrato su coppie di frasi. La complementarità suggerisce che un'aggregazione dei due motori potrebbe superare entrambi.

Il guadagno ha un costo in latenza: circa 4 secondi per claim contro decine di millisecondi, due ordini di grandezza. Il trade-off è esplicito: l'NLI resta appropriato per l'uso interattivo, l'LLM per l'elaborazione differita — che è la strategia adottata nella dimostrazione, dove i verdetti di entrambi i motori sono precalcolati sulle query canoniche, così che il confronto sia ispezionabile dall'utente.

Una conferma collaterale sui documenti propri. Precalcolare entrambi i motori sulle stesse 11 query produce 160 verdetti per motore, sugli stessi documenti e con le stesse evidenze. Non sono una misura di accuratezza — su questi documenti non esiste gold — ma la *distribuzione*

Stance Diversity	News	Social	H a priori del corpus social
Energia nucleare	0,545	—	—
Cambiamento climatico	0,322	**0,621**	1,000
Vaccini	0,229	**0,600**	1,000

Tabella 7.3: Diversità di stance comparata. L'ultima colonna riporta l'entropia a priori del corpus social, uniforme per costruzione (§4.3).

dei verdetti riproduce l'inversione di profilo misurata su ClimateFEVER: l'NLI emette 2% di SUPPORTED e 15% di REFUTED, l'LLM ribalta le proporzioni a 17% e 7%. Il comportamento osservato sul benchmark non è dunque un artefatto di ClimateFEVER: si ripresenta fuori campione, su un corpus giornalistico e su una knowledge base diversa. Entrambi restano prudenti — oltre tre quarti dei verdetti sono NOT_ENOUGH_EVIDENCE — il che è il comportamento atteso di un cancello di pertinenza tarato per non produrre falsi REFUTED.

7.3 Stance Diversity: media contro social

Su entrambi i temi con corpus social la diversità misurata è circa doppia rispetto ai media. La lettura immediata sarebbe controintuitiva rispetto al senso comune che associa i social alla polarizzazione. Va però sottoposta a due qualificazioni di segno opposto.

Il risultato solido. I valori dell'ecosistema news sono interpretabili in senso assoluto: il corpus è un campione naturale, e 0,229 sui vaccini significa che sulle query canoniche il materiale recuperabile è fortemente concentrato su una sola posizione. Questo è coerente con la misura indipendente della Sezione 4.2, che rileva circa il 3% di documenti AGAINST nell'intero corpus. Due misure ottenute per vie diverse — una sul pool recuperato, una sull'intero corpus — concordano, e la loro concordanza rafforza la conclusione che *la cronaca giornalistica su questi temi, nel campione considerato, è marcatamente omogenea*. È il risultato più difendibile del capitolo.

Il confronto, invece, è confondato. Il *rapporto* fra i due ecosistemi non è interpretabile come proprietà degli ecosistemi, per la ragione esposta nella Sezione 4.3: la differenza somma un effetto reale ignoto e un artefatto di campionamento. L'analisi completa, con la direzione dell'artefatto, è nella Sezione 8.3.1.

Un'osservazione collaterale. Il corpus social, pur avendo entropia a priori 1,000, produce pool con diversità 0,62 e 0,60, sensibilmente sotto il massimo. Lo scarto ha due spiegazioni non mutuamente esclusive: il retrieval per pertinenza concentra le prospettive — che sarebbe un risultato interessante di per sé, misurabile con il *diversity lift* — oppure l'errore di classificazione su NEUTRAL distorce la distribuzione misurata. Con i dati attuali non è possibile separare i due contributi, ed è precisamente ciò che il lift, affiancato a un'analisi di sensibilità sulla confidenza, permetterebbe di fare. Il valore social per il nucleare non è disponibile, non essendo stato individuato un dataset di tweet comparabile su quel tema.

			κ **di Cohen**		
Tema	n	Accordo	non pesato	lineare	**quadratico**
Energia nucleare	137	0,839	0,744	0,836	**0,904**
Cambiamento climatico	109	0,761	0,587	0,712	**0,814**
Vaccini	134	0,784	0,657	0,770	**0,856**
Complessivo	**380**	**0,797**	0,675	0,784	**0,867**

Tabella 7.4: Accordo fra i due annotatori umani sui giudizi di rilevanza. Il valore da riportare su una scala ordinale è quello a pesi quadratici; le altre due varianti sono date per confrontabilità con la letteratura, che cita più spesso la forma non pesata.

7.4 Retrieval

7.4.1 Accordo fra annotatori

Le 380 coppie del pool sono state giudicate **due volte, da due annotatori umani** — i due autori — che hanno lavorato in cieco l'uno rispetto all'altro sulle stesse linee guida scritte (Appendice C). Nessuna delle due serie è stata consultata durante la compilazione dell'altra: l'accordo misurato su annotazioni allineate strada facendo sarebbe gonfiato e non significherebbe nulla.

Il κ quadratico complessivo è 0,867 — *almost perfect* sulla scala di interpretazione convenzionale — e non scende sotto 0,81 su nessuno dei tre temi; il non pesato vale 0,675, *substantial*. Il divario fra le due varianti non è un artificio a proprio vantaggio ma il contenuto informativo della scelta: significa che il disaccordo, dove c'è, è quasi tutto fra gradi *adiacenti*.

È la struttura del disaccordo, più della sua media, a dire se le linee guida reggono. Sulle 380 coppie i due giudizi divergono 77 volte: 31 sul confine fra 0 e 1, 44 su quello fra 1 e 2, e soltanto **2 a due gradini di distanza** — i casi in cui un giudice dice "non pertinente" e l'altro "pienamente pertinente", nessuno dei quali sul nucleare. Non ci sono cioè coppie su cui i due annotatori abbiano letto documenti diversi: il disaccordo riguarda *quanto* un documento serva alla query, non *se* vi risponda. Il tema climatico resta il più difficile (κ quadratico 0,814 contro 0,904 del nucleare), coerentemente con query astratte su un corpus tematicamente saturo, dove il confine fra "parla del tema" e "risponde alla domanda" è il più sottile.

Le due serie non sono però intercambiabili, e la differenza è sistematica: il secondo annotatore assegna il grado 2 a 153 coppie contro 117 del primo, e in 39 casi promuove a "pienamente rilevante" un documento che il primo ha giudicato marginale (il passaggio inverso avviene 5 volte). È una soglia di generosità diversa, non un disaccordo sul merito, e va tenuta presente leggendo l'ablazione: alza i valori assoluti di tutte le metriche calcolate sulla seconda serie senza spostare il confronto fra sistemi.

7.4.2 Ablazione dei sistemi

La Tabella 7.5 riporta l'ablazione, calcolata due volte sulle due serie di giudizi.

Quanto l'ordinamento dipende da chi ha giudicato. Cinque sistemi su sei si ordinano allo stesso modo sulle due serie — *rerank* > *fusione* > *denso* > *RRF* > *BM25* — e su quei

		Annotatore 1			Annotatore 2		
#	**Sistema**	NDCG	MAP	R@20	NDCG	MAP	R@20
1	BM25 puro	0,616	0,488	0,583	0,643	0,494	0,604
2	Denso puro (bge)	0,656	0,538	0,701	0,719	0,563	0,699
3	Fusione RRF	0,653	0,535	0,671	0,704	0,548	0,673
4	Fusione, α=0,45	0,674	0,556	**0,702**	0,723	0,571	**0,708**
5	Fusione, α tarato	0,644	0,538	0,685	0,719	0,574	0,700
6	Fusione + reranking	**0,715**	**0,577**	**0,702**	**0,779**	**0,601**	**0,708**

Tabella 7.5: Ablazione del retrieval su 11 query, calcolata sulle due serie di giudizi indipendenti. NDCG è a cutoff 10; i run sono troncati alla profondità 20 a cui il pool è giudicato, quindi il MAP è un MAP@20.

cinque il τ_b di Kendall vale esattamente 1,0. Sui sei scende a 0,733, e l'intero scarto è imputabile a un solo sistema: la *fusione tarata*, quinta sulla prima serie e terza sulla seconda. Vale la pena guardare di quanto: sulla seconda serie supera il denso di 0,0006 di NDCG, cioè si colloca in un intervallo che 11 query non hanno la risoluzione per distinguere. Il τ_b registra quel sorpasso come un'inversione perché è una statistica d'ordine e ignora le distanze; la lettura corretta non è che il risultato sia instabile, ma che *è instabile esattamente sul sistema che questa sezione conclude non dover essere usato* (§7.4, taratura di α). Le conclusioni sostantive — il reranking come contributo maggiore, la fusione sopra entrambi i rami singoli e sopra RRF, BM25 ultimo — sono invarianti rispetto all'annotatore.

I valori assoluti sono invece sistematicamente più alti sulla seconda serie, di 3–6 punti di NDCG: quell'annotatore assegna più giudizi di piena rilevanza (153 contro 117) e c'è quindi più guadagno disponibile nel numeratore dell'NDCG. È la ragione per cui *i valori assoluti di un NDCG non sono confrontabili fra collezioni giudicate da persone diverse*, mentre i confronti interni alla stessa collezione lo sono. Salvo indicazione contraria i numeri commentati nel seguito sono quelli della prima serie.

Il reranking è il contributo più grande. Il secondo stadio porta l'NDCG@10 da 0,674 a 0,715 (+6,1% relativo; +7,8% sulla seconda serie), a Recall invariato per costruzione — riordina, non recupera. È coerente con l'attesa teorica e la conferma su dati propri. Il dettaglio per tema (Tabella 7.6) mostra però che il guadagno non è distribuito: viene quasi tutto dai vaccini (0,599 $\rightarrow$ 0,722), mentre sul nucleare, dove la fusione è già a 0,822, il riordino è sostanzialmente neutro. Il reranker serve dove il primo stadio lascia margine, non ovunque.

La fusione batte i rami singoli, ma il margine sul denso è sottile. 0,674 contro 0,656 del denso e 0,616 di BM25: +2,9% relativo sul denso e +9,4% su BM25. Il ramo denso porta la maggior parte del segnale e il contributo lessicale è reale ma modesto. La fusione pesata supera anche RRF (0,653), il che giustifica il parametro: combinare i punteggi conserva informazione che combinare i ranghi perde. Il dettaglio per tema (Tabella 7.6) mostra la ragione della complementarità: sul nucleare, dove pesano i termini tecnici, BM25 batte il denso (0,800 contro 0,737); sul clima, dove domina la parafrasi, crolla a 0,405 contro 0,576. È esattamente la complementarità ipotizzata in progettazione, e la fusione serve a non dover scegliere. L'inversione fra i due rami è però il risultato più fragile del capitolo: sulla seconda serie di giudizi il denso

NDCG@10 (Annotatore 1)	Nucleare	Clima	Vaccini
BM25 puro	0,800	0,405	0,591
Denso puro	0,737	0,576	0,634
Fusione pesata	**0,822**	**0,579**	0,599
Fusione + reranking	0,820	0,567	**0,722**

Tabella 7.6: Dettaglio per tema: il divario fra ramo sparso e denso si ribalta fra nucleare e clima, e il guadagno del reranking è concentrato sui vaccini.

α	0,1	0,2	0,3	0,4	**0,45**	0,5	0,6	0,8	0,9
NDCG@10 (Annot. 1)	0,661	0,673	0,667	0,677	**0,674**	0,669	0,660	0,640	0,627
NDCG@10 (Annot. 2)	0,720	0,731	0,725	0,721	**0,723**	0,712	0,710	0,692	0,672

Tabella 7.7: NDCG@10 in funzione del peso del ramo sparso. In grassetto il default adottato, sottolineato l'ottimo oracolo di ciascuna serie. La metrica è insensibile ad α nell'intervallo utile.

resta avanti anche sul nucleare (0,831 contro 0,770), e quello che sopravvive a entrambe le annotazioni è la *variazione del divario* — il vantaggio del denso passa da -6 punti sul nucleare a $+17$ sul clima nella prima serie, da $+6$ a $+17$ nella seconda — non il segno.

Tarare α su 11 query peggiora le prestazioni. È il risultato più istruttivo. Il sistema con α tarato in leave-one-topic-out (0,644) è *inferiore* a quello con il default (0,674); sulla seconda serie di giudizi la perdita si riduce a mezzo punto percentuale (0,719 contro 0,723) ma non cambia di segno. La ragione è visibile nella curva completa (Tabella 7.7): fra 0,1 e 0,5 la metrica è praticamente piatta, con un'escursione di 1,6 punti, e degrada solo oltre 0,6. L'ottimo *oracolo* della prima serie è $\alpha = 0{,}4$ con 0,6768, cioè +0,4% rispetto al default: una differenza priva di significato pratico. E i due annotatori collocano l'ottimo in punti diversi (0,4 contro 0,2), che è la firma del rumore. Con due soli temi di addestramento per fold la grid search seleziona quel rumore ($\alpha = 0{,}1$ sul fold del nucleare, su entrambe le serie) e generalizza peggio di un valore fissato a priori.

La conclusione è duplice. Il default $\alpha = 0{,}45$, scelto per motivi di dominio, si rivela entro lo 0,4% dall'ottimo misurabile: la scelta a priori era buona, e ora si può dirlo sui dati anziché sulla letteratura. Ma l'esperimento mostra anche che *su questa scala di dati la taratura di α non è un'operazione sensata*: non c'è segnale sufficiente a distinguere i valori nell'intervallo utile, e tarare introduce varianza senza ridurre distorsione.

Copertura dei giudizi. È 1,000 per cinque sistemi su sei, come atteso: il pool è l'unione dei loro run. L'unica eccezione è la fusione tarata (0,986 sulla prima serie, 0,982 sulla seconda), che a α diverso dal default pesca qualche documento fuori dal pool; quei documenti contano come non rilevanti e la penalizzano lievemente. L'effetto è di entità inferiore al divario osservato (3,0 punti di NDCG) e non ne ribalta il segno, ma va dichiarato.

7.5 Quadro d'insieme

Componente	**Benchmark**	**Risultato**	**Stato**
Retrieval, 6 sistemi	qrels propri (380)	NDCG@10 0,715	valutato
Accordo annotatori	2 umani, 380 coppie	κ quad. 0,867	*almost perfect*
Stance detection	VAST $\cup$ SemEval	Macro-F1 0,771	valutato
Stance, cross-dataset	VAST / SemEval	0,768 / 0,741	generalizza
Stance, dominio social	gold social	$\sim$0,48	calo analizzato
Fact-check NLI	ClimateFEVER	Macro-F1 0,350	valutato
Fact-check LLM	ClimateFEVER	Macro-F1 0,640	confronto controllato
Stance Diversity	query canoniche	0,229–0,621	misurato, confronto confondato
Summarization	—	—	non valutabile

Tabella 7.8: Stato di valutazione dei componenti.

8. Discussione e limiti

8.1 Findings trasversali

L'omogeneità informativa è misurabile. L'entropia normalizzata sulle stance predette è calcolabile su qualunque corpus testuale, senza dati relazionali, e restituisce un numero interpretabile. Il valore non sta nel particolare numero ottenuto ma nel fatto che l'echo chamber diventi una grandezza monitorabile, aprendo alla possibilità di confronti sistematici nel tempo o fra ambienti. Le condizioni sotto cui il confronto è lecito sono però più stringenti di quanto appaia, ed è la lezione principale del lavoro.

Ragionare batte classificare, ma non ovunque. A parità di evidenze un LLM locale di taglia contenuta supera nettamente un classificatore NLI specializzato, e lo supera proprio dove questo fallisce. Ma il profilo si ribalta su REFUTED. La conclusione corretta non è "l'LLM è migliore", bensì che i due approcci hanno errori *complementari* e che la scelta dipende da quale errore sia più costoso — o, meglio, che una loro combinazione meriterebbe di essere esplorata.

Il secondo stadio vale più di qualunque taratura. Sull'ablazione del retrieval, il reranking — che nessun iperparametro controlla — vale un guadagno dieci volte superiore a qualunque scelta di α, la cui taratura su questa scala di dati è addirittura controproducente. È un promemoria sull'ordine delle priorità in un sistema di IR.

Il grounding ha un prezzo e va pagato consapevolmente. Vincolare il modello alle sole evidenze recuperate elimina la fonte principale di allucinazione, ma limita la copertura a ciò che la knowledge base contiene: una claim recente riceve NOT_ENOUGH_EVIDENCE non perché sia infondata ma perché il sistema non sa. È corretto per uno strumento di verifica — l'astensione è preferibile all'affermazione arbitraria — ma va comunicato all'utente, perché un NEI non è un giudizio sulla claim.

8.2 Analisi degli errori

Il NEUTRAL come costrutto instabile. Il filo conduttore di gran parte degli errori è la classe NEUTRAL: riconosciuta eccellentemente sui benchmark (0,858) e quasi per nulla sui tweet (0,07–0,23), mentre le classi schierate reggono in entrambi i regimi. Lo schema esclude la spiegazione più semplice — un degrado generico fuori distribuzione, che colpirebbe tutte le classi — e indica che a cambiare è la *definizione* della classe. L'implicazione per il sistema è che la Stance Diversity misurata sul corpus social poggia, per una classe su tre, su una classificazione poco più che casuale; e poiché un classificatore che sbaglia in modo non sistematico tende a produrre distribuzioni più uniformi di quelle reali, l'errore agisce plausibilmente nella direzione di *gonfiare* la diversità misurata sul social.

SUPPORTED e la natura dell'inferenza. Il fallimento dell'NLI su SUPPORTED (0,065 a livello di claim) è quantitativamente il risultato più estremo del lavoro, e l'ablazione base/large

mostra che non si risolve con più capacità. La spiegazione proposta riguarda la natura del compito: nei dati reali l'evidenza raramente *ripete* la claim, la implica attraverso passaggi non esplicitati (dall'evidenza "la Francia produce il 70% della sua elettricità da fonte nucleare" alla claim "la Francia dipende in larga misura dal nucleare" occorre un passaggio di inferenza lessicale e quantitativa). Un classificatore addestrato su coppie di frasi apprende bene la contraddizione locale e male l'implicazione a più passi.

Falsi REFUTED e politiche di decisione. Durante lo sviluppo si è osservato che un fact-checker basato su recupero semantico su KB tematica produce falsi REFUTED con frequenza elevata: le evidenze riguardano il tema giusto ma non sempre la claim giusta, e l'NLI interpreta la divergenza di argomento come contraddizione. L'introduzione del cancello di pertinenza e l'innalzamento della soglia di REFUTED a 0,95 hanno convertito quei casi in NEI. È un esempio di come una scelta di *politica di decisione* possa incidere sul comportamento osservabile quanto la scelta del modello.

8.3 Minacce alla validità

8.3.1 Validità interna

Minaccia principale: confondimento fra ecosistema e campionamento. Il corpus social è campionato in modo stratificato sulle tre classi (entropia a priori = 1,000), quello news in modo naturale (circa il 3% di AGAINST). La differenza osservata confonde quindi due effetti:

$$\underbrace{H_{\text{social}} - H_{\text{news}}}_{\text{differenza osservata}} = \underbrace{\Delta_{\text{ecosistema}}}_{\text{effetto di interesse}} + \underbrace{\Delta_{\text{campionamento}}}_{\text{artefatto}}, \tag{8.1}$$

senza che i dati attuali consentano di separare i due termini. Sulla *direzione* dell'artefatto si può però ragionare con sicurezza: poiché la stratificazione porta l'entropia a priori del social al massimo possibile mentre il campionamento naturale del news restituisce un'entropia bassa, $\Delta_{\text{campionamento}} > 0$. L'artefatto agisce nella stessa direzione della conclusione riportata e ne *sovrastima* l'entità; non è però possibile escludere che $\Delta_{\text{ecosistema}}$ sia nullo o di segno opposto.

Le contromisure, in ordine crescente di costo ed efficacia, sono: *riformulare la conclusione*, riportando i valori news come misura assoluta e presentando il confronto come condizionato alla costruzione dei corpora — soluzione adottata in questa relazione; applicare il *diversity lift* (§5.5), che rapportando la diversità del pool a quella del proprio corpus è invariante rispetto alla distribuzione a priori e rende i due ecosistemi confrontabili al costo di una passata offline; oppure *ricostruire il corpus social con campionamento naturale*, mantenendo quello stratificato come esclusivo gold di valutazione dello stance detector — soluzione definitiva, che elimina il confondimento alla radice.

Minaccia secondaria: errore di misura asimmetrico. La Stance Diversity è calcolata su etichette predette, e la qualità del predittore è misurata sul social ($\sim 0{,}48$) ma **non sul news**, per assenza di gold su articoli. È quindi possibile che l'errore di misura sia di entità diversa nei due ecosistemi, e poiché l'errore tende a uniformare le distribuzioni, una differenza di accuratezza si tradurrebbe in una differenza spuria di diversità. Contromisure: annotare un

gold pilota sul news (dell'ordine di 150 documenti bastano per una stima grossolana) e condurre un'analisi di sensibilità ricalcolando la diversità sui soli documenti classificati con confidenza superiore a una soglia.

8.3.2 Validità esterna

I corpora sono **piccoli**: 1917 articoli e 1869 tweet. Sufficienti a dimostrare il funzionamento del sistema e a produrre misure indicative, non a caratterizzare l'ecosistema mediatico. I **temi** sono tre, tutti sull'asse scienza/politica: nulla autorizza a estendere le conclusioni ad altri assi di divisività. La **lingua** è esclusivamente l'inglese e tutti i modelli sono monolingui. La **finestra temporale** è quella delle sorgenti, il che rende i corpora una fotografia di un periodo e non una serie storica — proprio la dimensione che renderebbe interessante il monitoraggio. Va inoltre osservato che i due dataset social provengono da fonti diverse con schemi di annotazione originari diversi, il che aggiunge eterogeneità fra i due temi social.

8.3.3 Validità di costrutto

Il costrutto centrale è l'identificazione di **echo chamber** con **bassa entropia delle stance nel materiale recuperato**: operazionalizzazione ragionevole ma parziale, perché l'echo chamber riguarda l'esposizione effettiva di una persona nel tempo, mentre qui si misura la composizione di un insieme di documenti. Una copertura omogenea può inoltre riflettere un consenso scientifico legittimo anziché una distorsione informativa — distinzione che la metrica non può fare, e che è particolarmente rilevante proprio sui temi trattati. Un secondo aspetto è l'*invarianza per permutazione*, per cui una copertura prevalentemente neutra e una prevalentemente schierata ricevono lo stesso punteggio: è il motivo per cui l'interfaccia mostra sempre la distribuzione accanto al punteggio. Un terzo è la **dipendenza dal target** (§4.1), al punto che un target mal scelto può gonfiare la diversità del 50% senza che nulla sia migliorato: la metrica non è quindi proprietà del solo corpus, ma della coppia (corpus, target).

8.3.4 Validità delle conclusioni statistiche

Nessuna misura è accompagnata da intervalli di confidenza o test di significatività. Per le misure su benchmark ampi (stance su 4 255 esempi, fact-checking su 1 381 claim) la questione è meno pressante: le differenze osservate sono di entità tale da rendere implausibile che siano dovute al caso. Per la Stance Diversity, invece, il problema è concreto: le medie sono calcolate su 3–4 query per tema, ciascuna su un pool di 30 documenti, e con numerosità di questo ordine una differenza di qualche centesimo non è distinguibile dal rumore. Lo stesso vale per l'ablazione del retrieval, che poggia su 11 query: sufficiente a stabilire un ordinamento — risultato corroborato dall'invarianza di cinque sistemi su sei fra due serie di giudizi indipendenti — ma non a distinguere differenze piccole, come mostra proprio il sistema che si scambia di posto fra le due serie a fronte di 0,0006 di NDCG. Le contromisure appropriate sono riportare la deviazione standard fra query e ampliare l'insieme delle query.

8.4 Limiti

Confronto fra ecosistemi confondato
La differenza di diversità fra social e news è sovrastimata per costruzione dei corpora. I valori assoluti sul news restano validi.

Numero di query ridotto nel retrieval
Undici query bastano a ordinare i sistemi ma non a tarare α né a dare intervalli di confidenza. Il parametro b di BM25 resta un default motivato dal dominio e non tarato; l'esito della taratura di α rende plausibile, ma non dimostrato, che lo stesso valga per b.

Qrels non riconciliati
Le due annotazioni indipendenti servono a misurare l'accordo e la stabilità dell'ordinamento, ma le divergenze non sono state adjudicate in un'unica serie consolidata: i valori riportati restano quelli del primo annotatore, con il secondo come replica. Con soli due giudici, inoltre, il κ è esso stesso una stima rumorosa.

Il NEUTRAL come costrutto
La nozione di neutralità sui social differisce da quella dei benchmark; la Macro-F1 nel dominio applicativo scende a $\sim$0,48 quasi interamente per questa ragione.

Stance sul news non misurata
Manca un gold annotato su articoli giornalistici.

Copertura della knowledge base
Claim recenti o molto specifiche producono NEI: è il limite intrinseco di una KB statica.

Fact-checking end-to-end non valutato
La valutazione usa le evidenze del benchmark, quindi la qualità del recupero dalla KB propria non è quantificata.

Grounding non verificato sperimentalmente
L'assenza di ricorso alla conoscenza parametrica dell'LLM è imposta via prompt ma non verificata con un esperimento di controllo.

Summarization non valutata
In assenza di riassunti di riferimento la qualità non è quantificata: è una baseline ragionevole, non un componente validato.

Metadati di fonte non sfruttati
Orientamento, affidabilità e tier sono calcolati e persistiti su ogni documento ma non utilizzati a valle; la copertura del registro sul corpus è inoltre bassa.

8.5 Considerazioni etiche

Il rischio della falsa equivalenza. Presentare sempre tre colonne affiancate può suggerire che le tre posizioni abbiano pari fondamento. Su temi con un solido consenso scientifico questa è precisamente la distorsione nota come *false balance*. Il sistema adotta due contromisure parziali: la barra di diversità mostra le proporzioni *reali* del pool, rendendo visibile che una posizione è minoritaria anziché nasconderlo dietro colonne di uguale ampiezza; e il fact-checking affianca a ciascun documento un verdetto sulle sue affermazioni. Sono mitigazioni, non soluzioni: il problema è intrinseco all'interfaccia a colonne ed è dichiarato.

Nessun filtro automatico sulle fonti. Il registro di credibilità è usato per descrivere e, in prospettiva, per segnalare, mai per escludere automaticamente documenti. Un sistema che nascondesse silenziosamente determinate fonti eserciterebbe una curatela non trasparente, in conflitto con l'obiettivo di esporre alla pluralità. Le fonti di tier 3 sono mostrate ma non sono *mai* usate come evidenza nel fact-checking: la distinzione fra "ciò che si mostra" e "ciò su cui si fonda un verdetto" è la linea che il sistema traccia.

Reificazione delle posizioni e dati personali. Ridurre un testo argomentato a una di tre etichette è una semplificazione: il sistema conserva e mostra la confidenza, ma la struttura a tre colonne impone comunque una categorizzazione netta, e la classificazione va intesa come strumento di navigazione, non come giudizio sul testo. I corpora social contengono testi pubblici di utenti reali: il sistema non raccoglie né mostra identificativi d'autore, non ricostruisce profili e non collega testi allo stesso autore; i dataset impiegati sono pubblici e già anonimizzati alla fonte.

9. Conclusioni

9.1 Che cosa è stato ottenuto

Echo-Search realizza un approccio operativo e riproducibile alla misura dell'echo chamber. Dato un tema divisivo, il sistema recupera i documenti pertinenti da due ecosistemi con una pipeline identica, ne stima la posizione argomentativa, li bilancia per prospettiva, ne verifica le affermazioni contro una base di conoscenza locale e li sintetizza per punto di vista, producendo una misura scalare della diversità di opinione. Ripercorrendo le domande della Sezione 1.2:

RQ1 (misurabilità)
Risposta affermativa. La Stance Diversity è calcolabile su qualunque corpus testuale ed è stata analizzata nelle sue proprietà e nei suoi casi limite. Il lavoro ha inoltre identificato la condizione sotto cui il confronto fra due valori è lecito — comparabilità delle procedure di campionamento — e proposto una metrica derivata che ne è invariante.

RQ2 (confronto fra ecosistemi)
Risposta parziale e condizionata. Il risultato solido è che l'ecosistema news dei corpora costruiti è marcatamente omogeneo in senso assoluto (diversità 0,23–0,55; circa il 3% di documenti AGAINST), con due misure indipendenti che concordano. Il confronto con il social è confondato dalla differenza di campionamento e non è interpretabile come proprietà degli ecosistemi finché non si applica la contromisura.

RQ3 (motore di verdetto)
Risposta affermativa e quantificata. A parità di evidenze, su ClimateFEVER l'LLM locale porta la Macro-F1 da 0,350 a 0,640, con SUPPORTED da 0,065 a 0,753. Il profilo di errore dei due motori si rivela complementare: è il risultato più interessante e meno anticipato del lavoro.

RQ4 (fattibilità)
Risposta affermativa. L'intera pipeline, che include sei modelli neurali distinti fra cui un LLM da 7 miliardi di parametri, è eseguibile su una GPU portatile da 6 GB, interamente offline, con risultati riproducibili.

A queste si aggiunge un risultato non previsto fra le domande iniziali, emerso dall'ablazione del retrieval: sul regime di dati considerato **la taratura di α non è un'operazione sensata**, perché la metrica è piatta nell'intervallo utile del parametro e la procedura corretta — la validazione leave-one-topic-out — peggiora le prestazioni selezionando rumore.

9.2 Due lezioni trasversali

La prima riguarda la **fragilità delle metriche derivate**. La Stance Diversity è elegante e interpretabile, ma è calcolata su etichette predette da un classificatore e su un campione costruito da una procedura. Il lavoro ha incontrato entrambe le dipendenze nella loro forma concreta: un target mal scelto che gonfiava la diversità del 50%, e un campionamento stratificato che ne determina in larga parte il valore su un intero ecosistema. Una metrica derivata va sempre accompagnata dalla misura della qualità dei suoi ingredienti.

La seconda riguarda il **rapporto fra specializzazione e capacità generale**. Il confronto NLI/LLM mostra che un modello specializzato e addestrato esattamente sul compito può essere superato da un generalista di taglia contenuta, e superato proprio dove il primo fallisce; ma mostra anche che la superiorità non è uniforme, e che là dove il compito si riduce al riconoscimento di un'incompatibilità locale la specializzazione tiene. La lettura utile non è gerarchica ma diagnostica: i due approcci sbagliano in modo diverso, ed è la struttura dell'errore — non la media — a indicare quale usare.

9.3 Sviluppi futuri

Consolidamento. *Diversity lift*: calcolare $H(p^{\text{corpus}})$ per entrambi gli ecosistemi e riportare il lift accanto alla diversità assoluta; è la contromisura al confondimento principale e richiede una sola passata offline. *Gold pilota sul news*, per stimare la Macro-F1 dello stance detector e valutare la simmetria dell'errore di misura fra ecosistemi. *Più query* (40–50), per intervalli di confidenza e test di significatività, e l'*adjudicazione* delle 77 divergenze fra i due annotatori in un'unica serie consolidata, che è il passo che manca perché i qrels smettano di essere il giudizio di una persona con una replica accanto.

Estensioni del sistema. Sfruttare i *metadati di fonte* già calcolati, mostrandoli all'utente e affiancando alla Stance Diversity una *Source Diversity* sull'orientamento delle fonti del pool. *Parallelizzare il ramo di fact-checking*, che è I/O-bound e non appartiene al cammino critico. *Persistere l'indice della knowledge base*, i cui embedding sono attualmente ricalcolati a ogni avvio. Affiancare un *RAG online* alla KB statica, mantenendo l'LLM locale come motore di ragionamento, per verificare anche claim recenti.

Direzioni di ricerca. *Combinare i due motori di verdetto*, poiché i profili di errore sono complementari: l'NLI come filtro rapido e l'LLM sui casi incerti, oppure una votazione pesata per classe. Un *confronto multi-LLM* fra modelli locali $\leq$10B sul medesimo protocollo. La *verifica sperimentale del grounding* con evidenze contraffatte. La *ri-annotazione del NEUTRAL* con linee guida specifiche per il dominio social. E la *dimensione temporale*: corpora su più finestre per lo stesso tema, che trasformerebbero la misura di diversità da fotografia in serie storica — la forma in cui il monitoraggio dell'echo chamber diventa davvero informativo.

A. Iperparametri

Sezione	Parametro	Valore
Corpus	chunk / overlap	512 / 128 token (25%)
BM25	k_1 / b	1,2 / 0,60
Dense	modello	`BAAI/bge-base-en-v1.5` (768-dim)
	indice	FAISS `IndexFlatIP`; max-pooling sui chunk
Fusione	α / β	0,45 / 0,55, normalizzazione min-max
	pool	50 (baseline RRF con $k_{\text{rrf}} = 60$)
Reranker	modello / top-n	`BAAI/bge-reranker-base` / 30
Stance	modello	DeBERTa-v3-base fine-tunato (v. Tab. 5.1)
	batch inferenza / troncamento	16 / 400 parole
Colonne	documenti per colonna	5
Fact-check	KB	1589 articoli Wikipedia (introduzioni)
	cancello di pertinenza	coseno $\geq$ 0,62; 4–5 evidenze per claim
	NLI	`DeBERTa-v3-base-mnli-fever-anli`
	soglie	SUPPORTED $\geq$ 0,75; REFUTED $\geq$ 0,95
	LLM	`qwen2.5:7b` (Ollama), temperatura 0, timeout 180 s
Summarization	modello	`google/flan-t5-base`
	frasi estratte / beam	10 / 4 (`do_sample=False`)
	max_new_tokens / no_repeat	200 / 3

Tabella A.1: Iperparametri del sistema. Nel percorso interattivo beam e token sono ridotti (2 / 120).

B. Prompt del motore LLM

Prompt di sistema effettivamente usato. Si notino l'istruzione di grounding puro, la definizione esplicita delle tre classi e il vincolo di formato che rende la risposta parsabile.

```
You are a rigorous fact-checking assistant. You receive a CLAIM and a
numbered list of EVIDENCE passages. Using ONLY the evidence (never prior
knowledge), decide:
- SUPPORTED: the evidence confirms/entails the claim;
- REFUTED: the evidence contradicts the claim;
- NOT_ENOUGH_EVIDENCE: the evidence is insufficient, unrelated, or ambiguous.
Reply ONLY with JSON: {"verdict": "SUPPORTED|REFUTED|NOT_ENOUGH_EVIDENCE",
"reasoning": "<one concise sentence citing the evidence used>"}.
```

Il messaggio utente ha la forma `CLAIM: ...` seguita da `EVIDENCE:` e dall'elenco numerato delle evidenze recuperate. Il parser normalizza le varianti che i modelli producono spontaneamente (`SUPPORTS`, `TRUE`, `ENTAILMENT` → SUPPORTED; `REFUTES`, `FALSE`, `CONTRADICTION` → REFUTED; `NEI`, `INSUFFICIENT`, `UNKNOWN` → NOT_ENOUGH_EVIDENCE) e ripiega su NOT_ENOUGH_EVIDENCE in assenza di segnale o in caso di errore di rete.

C. Linee guida di annotazione dei qrels

Si annota la **rilevanza del documento rispetto alla query**: non la sua stance, non la sua veridicità, non la qualità della fonte. La regola che governa tutte le altre è che **rilevante non significa condivisibile né vero**: un articolo che nega l'origine antropica del riscaldamento, se risponde alla query "*is climate change caused by humans*", è pienamente rilevante.

Il punto critico della scala è il confine fra 0 e 1. Definirlo per intenzione ("parla del tema ma non ha rapporto con la query" contro "tratta il tema ma non risponde") lo lascia operativamente ambiguo, e l'ambiguità morde esattamente dove la query è astratta e il corpus tematicamente saturo — cioè sulle query climatiche, che restano infatti il tema di minore accordo (Tabella 7.4). La specifica è perciò formulata come *test verificabile sul testo*, non come descrizione di un'intenzione.

Voto	Test operativo
2	Si sa *indicare la frase* del documento che costituisce la risposta alla query.
1	Non c'è una frase-risposta, ma il documento dà contesto utile o tocca la domanda di lato: lo si aprirebbe come terzo o quarto risultato ricavandone qualcosa.
0	Il legame con la query è *solo tematico*: il documento parla del tema ma non della domanda. Include il fuori tema puro.

Corollari, dedotti da casi reali del corpus.

- Se la query chiede un **costo**, serve un costo: una cifra, una stima o un'affermazione esplicita su chi paga e quanto. Una disputa su trasferimenti di fondi fra enti pubblici non è il costo di una politica; e il costo *dei danni* non è il costo *della politica*, hanno segno opposto.
- Se la query chiede una **relazione** fra due cose (clima $\leftrightarrow$ eventi estremi, nucleare $\leftrightarrow$ clima), il testo deve *asserire* la relazione: non basta che entrambi i termini compaiano.
- Se la query chiede un **rischio** o un **effetto**, il documento deve parlare di quel rischio, non del tema in cui il rischio esiste. Il fallimento finanziario di un progetto non è un "rischio dell'energia nucleare" se il testo non lo inquadra così.
- Il **duplicato sindacato** prende lo stesso voto della sua copia: il corpus contiene molte riprese della stessa storia d'agenzia, che sono un'unica decisione.
- In dubbio fra 1 e 0 si scelga 0; fra 2 e 1 si scelga 1.

Procedura. Ogni annotatore compila il proprio foglio senza consultare l'altro durante il lavoro: l'accordo misurato su annotazioni allineate strada facendo è gonfiato e non significa nulla. Il κ si calcola *prima* di qualunque riconciliazione; solo dopo si adjudicano le divergenze per produrre i qrels definitivi. Del protocollo è eseguito il primo passo — le due annotazioni cieche e il κ (Tabella 7.4) —; l'adjudicazione resta fra gli sviluppi (§9.3), e i risultati riportati usano la serie del primo annotatore.

D. Riproducibilità

Il sistema è eseguibile a partire dagli indici pre-costruiti; la demo carica risultati precalcolati per le query canoniche, così da essere istantanea e non richiedere GPU a runtime.

```
# ambiente
uv sync --extra dev
uv run python -m spacy download en_core_web_sm

# costruzione dei dati (ogni script produce un MANIFEST.json con hash SHA-256)
uv run --extra data python scripts/build_corpora.py        # corpus news (CC-News)
uv run python scripts/build_social_corpus.py               # corpus social (tweet)
uv run python scripts/build_kb.py                          # KB Wikipedia
uv run python scripts/build_stance_splits.py               # split VAST + SemEval
uv run --extra data python scripts/index_corpus.py         # indici BM25 + FAISS
uv run python scripts/build_qrels_annotation.py            # fogli qrels da annotare

# addestramento e valutazione
uv run python scripts/train_stance.py                      # fine-tuning stance
uv run python scripts/eval_stance.py                       # benchmark stance
uv run python scripts/evaluate_pivot.py                    # stance social + diversity
uv run python scripts/eval_climatefever.py --engine nli    # fact-check, motore NLI
uv run python scripts/eval_climatefever.py --engine llm    # fact-check, motore LLM
uv run python scripts/eval_retrieval.py                    # ablazione retrieval
uv run python scripts/eval_agreement.py                    # kappa fra i due annotatori

# esecuzione e test
uv run python main.py "risks of nuclear energy" --topic nuclear_energy
uv run streamlit run dashboard.py
uv run pytest tests -q                                     # 174 test
```

Bibliografia

[1] S. Xiao, Z. Liu, P. Zhang, N. Muennighoff. *C-Pack: Packed Resources for General Chinese Embeddings (BGE)*. 2023.

[2] S. Robertson, H. Zaragoza. *The Probabilistic Relevance Framework: BM25 and Beyond*. Foundations and Trends in Information Retrieval, 2009.

[3] J. Carbonell, J. Goldstein. *The Use of MMR, Diversity-Based Reranking for Reordering Documents and Producing Summaries*. Proc. SIGIR, 1998.

[4] M. Cinelli, G. De Francisci Morales, A. Galeazzi, W. Quattrociocchi, M. Starnini. *The Echo Chamber Effect on Social Media*. PNAS, 2021.

[5] N. Hassan, F. Arslan, C. Li, M. Tremayne. *Toward Automated Fact-Checking: Detecting Check-worthy Factual Claims by ClaimBuster*. Proc. KDD, 2017.

[6] T. Diggelmann, J. Boyd-Graber, J. Bulian, M. Ciaramita, M. Leippold. *CLIMATE-FEVER: A Dataset for Verification of Real-World Climate Claims*. 2020.

[7] J. Cohen. *A Coefficient of Agreement for Nominal Scales*. Educational and Psychological Measurement, 1960.

[8] P. He, J. Gao, W. Chen. *DeBERTaV3: Improving DeBERTa using ELECTRA-Style Pre-Training with Gradient-Disentangled Embedding Sharing*. Proc. ICLR, 2023.

[9] V. Karpukhin et al. *Dense Passage Retrieval for Open-Domain Question Answering*. Proc. EMNLP, 2020.

[10] J. Johnson, M. Douze, H. Jégou. *Billion-scale Similarity Search with GPUs*. IEEE Transactions on Big Data, 2019.

[11] J. Thorne, A. Vlachos, C. Christodoulopoulos, A. Mittal. *FEVER: a Large-scale Dataset for Fact Extraction and VERification*. Proc. NAACL, 2018.

[12] E. Pariser. *The Filter Bubble: What the Internet Is Hiding from You*. Penguin Press, 2011.

[13] P. Lewis et al. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. Proc. NeurIPS, 2020.

[14] G. V. Cormack, C. L. A. Clarke, S. Buettcher. *Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods*. Proc. SIGIR, 2009.

[15] N. Reimers, I. Gurevych. *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. Proc. EMNLP, 2019.

[16] S. Mohammad, S. Kiritchenko, P. Sobhani, X. Zhu, C. Cherry. *SemEval-2016 Task 6: Detecting Stance in Tweets*. Proc. SemEval, 2016.

[17] C. E. Shannon. *A Mathematical Theory of Communication*. Bell System Technical Journal, 1948.

[18] E. Allaway, K. McKeown. *Zero-Shot Stance Detection: A Dataset and Model using Generalized Topic Representations (VAST)*. Proc. EMNLP, 2020.

[19] W. Yin, J. Hay, D. Roth. *Benchmarking Zero-shot Text Classification: Datasets, Evaluation and Entailment Approach*. Proc. EMNLP, 2019.